
StreamForest: Efficient Online Video Understanding with Persistent Event Memory

Xiangyu Zeng^{*1}, Kefan Qiu^{*1}, Qingyu Zhang^{*1}, Xinhao Li¹, Jing Wang¹, Jiaxin Li¹
Ziang Yan^{3,2}, Kun Tian⁴, Meng Tian⁵, Xinhai Zhao⁴, Yi Wang², Limin Wang^{†1}
¹Nanjing University ²Shanghai AI Laboratory ³Zhejiang University
⁴Noah's Ark Lab, Huawei ⁵Yinwang Intelligent Tech.

<https://github.com/MCG-NJU/StreamForest>

Abstract

Los Multimodal Large Language Models (MLLMs) han logrado recientemente avances notables en comprensión de video. Sin embargo, su efectividad en escenarios de streaming en tiempo real sigue siendo limitada debido a las restricciones de almacenamiento de características visuales históricas y al razonamiento espaciotemporal insuficiente en tiempo real. Para abordar estos desafíos, proponemos **StreamForest**, una arquitectura novedosa diseñada específicamente para comprensión de streaming video. En el centro de StreamForest se encuentra el Persistent Event Memory Forest, un mecanismo de memoria que organiza adaptativamente los video frames en múltiples estructuras arbóreas a nivel de evento. Este proceso está guiado por funciones de penalización basadas en distancia temporal, similitud de contenido y frecuencia de merge, permitiendo una retención eficiente de memoria a largo plazo bajo recursos computacionales limitados. Para mejorar la percepción en tiempo real, introducimos una Fine-grained Spatiotemporal Window, que captura señales visuales detalladas de corto plazo para mejorar la percepción de la escena actual. Además, presentamos **OnlineIT**, un dataset de instruction-tuning adaptado a tareas de streaming video. OnlineIT incrementa significativamente el rendimiento de los MLLMs tanto en percepción en tiempo real como en predicción futura. Para evaluar la generalización en aplicaciones prácticas, introducimos **ODV-Bench**, un nuevo benchmark centrado en comprensión de streaming video en tiempo real en escenarios de conducción autónoma. Los resultados experimentales demuestran que StreamForest alcanza rendimiento de estado del arte, con exactitudes de 77.3% en StreamingBench, 60.5% en OVBench y 55.6% en OVO-Bench. En particular, incluso bajo compresión extrema de visual tokens (limitada a 1024 tokens), el modelo conserva el 96.8% de su exactitud promedio en ocho benchmarks respecto a la configuración por defecto. Estos resultados subrayan la robustez, eficiencia y capacidad de generalización de StreamForest para comprensión de streaming video.

1 Introducción

En los últimos años, los multimodal large language models han logrado avances significativos en tareas de video understanding, demostrando sólidas capacidades de comprensión semántica y razonamiento en videos de distintas duraciones y escenarios [30, 52, 31, 35]. Beneficiados por el pretraining a gran escala y por capacidades mejoradas de modelado cross-modal, estos modelos han

* Equal contribution.

† Corresponding author.

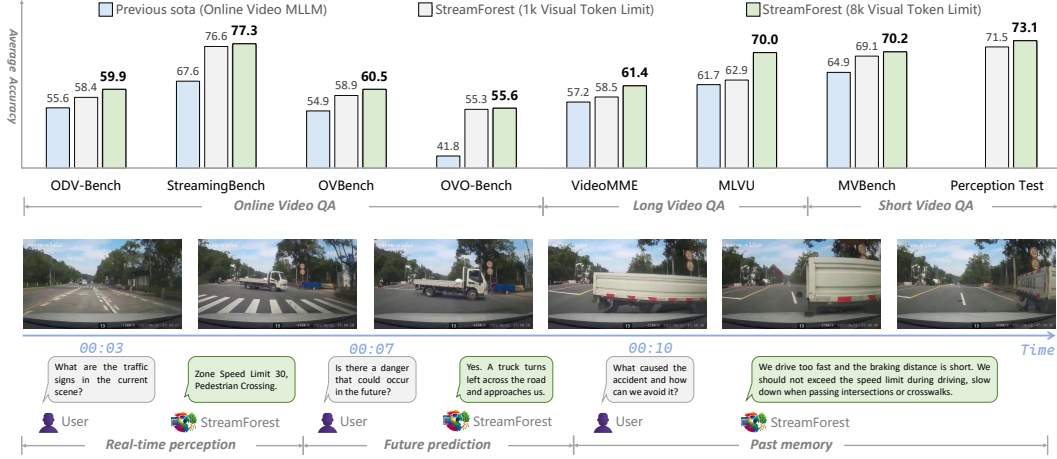


Figure 1: StreamForest achieves strong performance across various evaluation benchmarks while using significantly fewer visual tokens. It effectively handles key tasks in streaming video scenarios, including past memory, real-time perception, and future prediction.

sido ampliamente adoptados en diversos dominios [28, 42, 55, 59]. Sin embargo, con la creciente demanda de procesamiento inteligente en tiempo real en aplicaciones online como conducción autónoma [49], live video streaming [6] y robótica [79], los investigadores han desplazado cada vez más su foco desde el offline video understanding convencional hacia la tarea más desafiante de procesamiento de video en streaming [5, 23, 46].

En el campo de streaming video understanding, almacenar eficientemente las características de frames de video que llegan de forma continua sigue siendo un problema desafiante y de larga data. Para mitigar la sobrecarga de almacenamiento y cómputo asociada a frames pasados, el trabajo previo ha empleado principalmente dos estrategias de reducción de características visuales: compresión durante el muestreo [5, 46, 64] y compresión durante el almacenamiento [52, 72, 23]. La compresión durante el muestreo reduce gran parte de las características visuales entrantes, lo que limita severamente la capacidad del modelo para el razonamiento espaciotemporal fino. Como resultado, solo puede realizar una resumización semántica gruesa de la escena actual. En cambio, la compresión durante el almacenamiento suele implicar fusionar o descartar frames adyacentes según la similitud entre frames. Aunque es más eficiente en memoria, esta estrategia es propensa a perder acciones críticas en primer plano debido al ruido de fondo. También puede producir una fusión local excesiva, introduciendo irregularidades espaciotemporales que degradan la capacidad del modelo para retener y razonar sobre eventos clave a lo largo del tiempo.

Para abordar los desafíos de streaming video understanding, proponemos una arquitectura novedosa llamada **StreamForest**. En su núcleo se encuentra el **Persistent Event Memory Forest**, un mecanismo diseñado para almacenar y gestionar eficientemente información visual de largo plazo. Este sistema de memoria permite que un MLLM procese streaming video ultralargo a una tasa constante de 1 fps organizando dinámicamente segmentos de video en una estructura de árbol basada en límites de eventos. La fusión de segmentos está guiada por tres funciones de penalización que consideran distancia temporal, similitud de contenido y frecuencia de fusión, garantizando una jerarquía de memoria adaptativa y significativa. Para mejorar la percepción en tiempo real, introducimos una **Fine-grained Spatiotemporal Window**, que extrae ricas características espaciotemporales locales de frames cercanos. Este módulo permite que el MLLM comprenda mejor la escena actual al enfocarse en contexto visual temporalmente relevante. También presentamos **OnlineIT**, un dataset de fine-tuning diseñado específicamente para streaming video understanding. OnlineIT mejora la capacidad del MLLM para percibir el momento presente y anticipar eventos futuros aprovechando tanto observaciones recientes como señales históricas de largo plazo. Aborda el problema de las alucinaciones causadas por cambios de distribución espaciotemporal entre frames pasados y actuales. Además, introducimos **ODV-Bench**, un nuevo benchmark para evaluar streaming video understanding en escenarios de conducción autónoma. ODV-Bench enfatiza la percepción en tiempo real y la predicción futura, proporcionando un marco sistemático para evaluar la generalización y la efectividad en el mundo real de los streaming video MLLMs en tareas downstream.

Realizamos experimentos extensivos en benchmarks tanto de online como de offline video understanding para validar la efectividad de StreamForest. Bajo la configuración por defecto con un límite de 8192 visual tokens, StreamForest supera significativamente a los MLLMs previos de estado del arte para streaming video understanding. Alcanza una exactitud promedio de 77.3% en StreamingBench, 60.5% en OVBench y 55.6% en OVO-Bench. StreamForest también iguala o supera el rendimiento de los principales MLLMs de offline video understanding tanto en benchmarks de video largo como corto, a pesar de operar en una configuración de entrada de streaming video. Además, StreamForest demuestra una fuerte resiliencia bajo compresión extrema. Con un límite reducido de solo 1024 visual tokens, retiene el 96.8% de su rendimiento promedio en ocho benchmarks en comparación con la configuración por defecto. Estos resultados resaltan la robustez y eficiencia de nuestro enfoque para procesar continuamente entradas de streaming video.

2 Trabajo relacionado

Multimodal Large Language Model. Extender las capacidades multimodales desde imágenes estáticas hacia secuencias de video dinámicas introduce complejidad adicional, lo que exige que los modelos posean mayores capacidades para modelar dependencias de largo alcance y comprender eventos [30, 40, 81, 41, 71, 58]. Los avances recientes en MLLMs para video han introducido una variedad de estrategias innovadoras para enfrentar los desafíos de procesar y razonar eficientemente sobre entradas de video largas [37, 42, 29, 51, 33]. LongVILA [7] propone un sistema de Multimodal Sequence Parallelism para modelado de contexto largo, habilitando entrenamiento e inferencia paralelos eficientes sobre contenido de video extendido. Sin embargo, la mayor parte de la investigación actual en video understanding sigue centrada en escenarios offline [57, 69, 62, 34], donde el modelo tiene acceso completo a la secuencia de video antes de la inferencia. Aunque esta configuración facilita el modelado semántico global, resulta insuficiente en escenarios de streaming, donde se requiere comprensión en tiempo real de escenas en evolución continua. Por lo tanto, el desarrollo de modelos diseñados específicamente para online video understanding es de importancia crítica.

Streaming Video Understanding. En aplicaciones del mundo real, los usuarios esperan cada vez más que los MLLMs soporten procesamiento online e interacción en tiempo real. Esta demanda ha impulsado un interés creciente en la tarea de streaming video understanding. Recientemente, varios trabajos han explorado esta área emergente [5, 72, 63, 11, 61, 23]. Sin embargo, la mayoría de los enfoques existentes para streaming video understanding están diseñados principalmente para streaming dense video captioning [5, 60, 32, 47, 12], centrándose únicamente en resumir contenido semántico a partir de frames visuales. Como resultado, tienen dificultades para manejar tareas esenciales como memory recall y percepción en tiempo real, que son críticas para un streaming video understanding integral. Además, en busca de eficiencia computacional, muchos métodos aplican compresión agresiva a secuencias de frames de video [46, 74, 64], lo que los vuelve inadecuados para tareas complejas y dinámicas que requieren comprensión espaciotemporal fina y en tiempo real, como la conducción autónoma. Para abordar estas limitaciones, nuestro objetivo es desarrollar un enfoque más generalizable y práctico para online video understanding. Este enfatiza características espaciotemporales finas en el momento de la consulta y soporta almacenamiento persistente de memoria basado en eventos.

3 Metodología

3.1 Arquitectura de Streaming Video Understanding: StreamForest

En esta sección detallamos nuestro StreamForest propuesto. En particular, el diseño central de StreamForest reside en Fine-grained Spatiotemporal Window y Persistent Memory Forest, que trabajan en conjunto para permitir que el modelo retenga memorias de largo plazo de eventos pasados mientras sostiene percepción en tiempo real.

3.1.1 Fine-grained Spatiotemporal Window

Para satisfacer los requisitos de percepción espaciotemporal en tiempo real de streaming video understanding, introducimos la Fine-grained Spatiotemporal Window (FSTW). Observamos que en aplicaciones prácticas, la mayoría de las pistas que requieren razonamiento espaciotemporal




Figure 2: Overview of our proposed StreamForest. The Fine-grained Spatiotemporal Window captures instance-level spatiotemporal features, while the Persistent Event Memory Forest adaptively organizes event-level representations into a set of tree structures. Dashed arrows and feature tokens illustrate potential operations performed during each memory update iteration.

fino se concentran cerca del momento de la pregunta. Por ello, retenemos solo características espaciotemporales finas de corto plazo a nivel de segundos.

En concreto, la FSTW consta de dos componentes: percepción en tiempo real y memoria espaciotemporal de corto plazo. La percepción en tiempo real muestrea directamente características visuales de alta resolución del frame actual, que se codifican con información posicional espaciotemporal. A medida que llegan nuevos frames, los frames más antiguos se comprimen a lo largo de la dimensión espacial y se transfieren a la memoria espaciotemporal de corto plazo. Al mismo tiempo, el modelo calcula similitud entre frames nuevos y antiguos para habilitar la segmentación posterior a nivel de evento. La memoria espaciotemporal de corto plazo mantiene una secuencia de frames con duración de t_s segundos. Cuando su capacidad se excede, las características visuales sobrantes se descargan al Persistent Event Memory Forest. Segmentamos características visuales continuas en meta-eventos identificando la posición con el mínimo local de similitud entre frames en la secuencia. Esto garantiza que cada meta-evento capture una transición espaciotemporal coherente. Un meta-evento se trata como un nodo independiente, compuesto por una colección de visual tokens de frames consecutivos similares. Estos nodos forman la base de la memoria de largo plazo del MLLM.

3.1.2 Persistent Event Memory Forest

Para procesar eficientemente características de frames de video que llegan de forma continua en escenarios de streaming, proponemos Persistent Event Memory Forest (PEMF), una arquitectura de memoria diseñada específicamente para soportar memoria de largo plazo en el contexto de streaming video. A diferencia de métodos previos que dependen de compresión directa por similitud entre frames [52] o jerarquías de memoria estáticas [23], PEMF comprime y organiza adaptativamente la información de video a nivel de evento. Construye una memoria jerárquica con estructura de árbol guiada por tres funciones de penalización, permitiendo que el modelo retenga contenido semánticamente rico y no redundante mientras gestiona la memoria eficientemente a medida que evoluciona en el tiempo. Para controlar el crecimiento de memoria, imponemos un límite superior L_q sobre la cantidad de tokens de memoria de largo plazo almacenados en PEMF. Cuando este límite se supera, PEMF realiza consolidación jerárquica de memoria fusionando adaptativamente nodos de eventos adyacentes en nodos únicos dentro de la estructura arbórea. La selección de nodos a fusionar está guiada por tres funciones de penalización que consideran distancia temporal, similitud de contenido y frecuencia de fusión, garantizando que la memoria se mantenga informativa y compacta.

Penalización por similitud. En videos largos, los segmentos de video adyacentes suelen exhibir alta similitud visual, lo que produce una redundancia sustancial de características. Por ello, introducimos una penalización por similitud que fomenta la fusión de nodos de eventos con contenido visual altamente similar. Debido a diferencias en la duración de los eventos, dos nodos de eventos candidatos

(denotados como x_i, x_{i+1}) pueden contener diferentes cantidades de visual tokens. Para manejar esta discrepancia, inspirados en ToMe [3], adoptamos un enfoque de matching sobre grafos bipartitos. En particular, tratamos las características visuales de los dos nodos de eventos como conjuntos en un grafo bipartito y calculamos similitudes por pares entre tokens a través de estos conjuntos. Sea $X_i \in \mathbb{R}^{n_i \times d}$ la representación de características de visual tokens del nodo de evento x_i , donde n_i es la cantidad de tokens en x_i . Calculamos la matriz de similitud coseno por pares $S_i = \text{sim}(X_i, X_{i+1}) \in \mathbb{R}^{n_i \times n_{i+1}}$, y seleccionamos los k_i puntajes de similitud más altos, correspondientes a los pares de tokens más similares entre los dos nodos de eventos. La penalización por similitud P_s se define como uno menos el promedio de estos k_i puntajes de similitud más altos:

$$P_s(x_i, x_{i+1}) = 1 - \frac{1}{k_i} \sum_{(p,q) \in \mathcal{T}_i} S_i^{(p,q)}, \quad \mathcal{T}_i = \text{argTopK}_{(p,q)}(S_i^{(p,q)}, k_i). \quad (1)$$

Penalización por conteo de fusiones. Cuando los nodos de eventos participan repetidamente en fusiones jerárquicas de memoria con estructura arbórea, sus detalles visuales pueden degradarse gradualmente debido a la pérdida acumulada de información. Esta degradación puede conducir a inconsistencias espaciotemporales locales, deteriorando en última instancia la exactitud del long-term video understanding. Para mitigar este problema, introducimos una penalización por conteo de fusiones como término de regularización. Esta penaliza nodos excesivamente fusionados y fomenta un proceso de integración de memoria más equilibrado, preservando así la fidelidad de cada representación de evento. Sea c_i el conteo histórico de fusiones del nodo de evento x_i , y sea c_{max} su valor máximo en el instante de consulta. Definimos la penalización por conteo de fusiones P_m como sigue:

$$P_m(x_i, x_{i+1}) = \frac{c_i + c_{i+1}}{2c_{max}}. \quad (2)$$

Penalización por distancia temporal. En escenarios reales de streaming video understanding, los frames temporalmente más cercanos al momento actual de la consulta suelen contener información más relevante. Esta observación sugiere que las características visuales recientes deben preservarse con mayor fidelidad, mientras que las históricas pueden comprimirse de manera más agresiva. Para implementar esta intuición, introducimos una penalización por distancia temporal, que anima al modelo a retener representaciones más detalladas de eventos temporalmente próximos al tiempo que promueve el olvido de detalles de eventos distantes en el pasado. Sea t_q el tiempo actual de consulta o interacción y sea t_i el tiempo del evento i . El cálculo de t_i se detalla en el Apéndice A. Definimos la penalización temporal P_t como sigue:

$$P_t(x_i, x_{i+1}) = 1 - \frac{d_i + d_{i+1}}{2}, \quad d_i = \frac{t_q - t_i}{t_q}. \quad (3)$$

Penalización total. Incorporamos las tres penalizaciones anteriores para guiar el proceso adaptativo de fusión de nodos de eventos en PEMF, donde la combinación de estos tres factores determina la prioridad de fusión de pares de nodos de eventos.

$$P(x_i, x_{i+1}) = w_s P_s(x_i, x_{i+1}) + w_m P_m(x_i, x_{i+1}) + w_t P_t(x_i, x_{i+1}). \quad (4)$$

Los pesos de penalización w_s , w_m y w_t determinan conjuntamente el comportamiento de PEMF. Cuando solo se aplica la penalización por similitud, la estrategia degenera en compresión basada en similitud. Usar solo la penalización por conteo de fusiones conduce a un comportamiento similar al downsampling uniforme. Cuando la penalización por distancia temporal se usa de forma aislada, el método aproxima FIFO. Al ajustar estos pesos de penalización, nuestro método habilita un trade-off flexible entre estas estrategias, permitiéndole adaptarse eficazmente a varias tareas de streaming y equilibrar el ahorro eficiente de almacenamiento con la retención de información relevante para la tarea en diversos escenarios del mundo real.

Los nodos seleccionados para fusionarse se determinan identificando el par con el menor puntaje total de penalización. Empleamos ToMe [3] para el proceso de fusión, comprimiendo el número de visual tokens hasta la mitad del total de tokens del par de nodos seleccionado. Al recibir una consulta del usuario, las características visuales de todos los nodos raíz en PEMF, junto con todas las características visuales almacenadas en FSTW, se introducen en el LLM para soportar interacción en tiempo real y en streaming.

3.2 Dataset de instruction-tuning: OnlineIT

Los datasets offline existentes para long video suelen exhibir sesgo distribucional, donde la evidencia clave para responder preguntas suele concentrarse en la mitad del video. Como resultado, los MLLMs ajustados con esos datos tienden a sobreenfatizar contenido histórico, lo que puede conducir a alucinaciones al interpretar correctamente el momento actual. Aunque se han publicado algunos datasets para streaming video understanding [5, 60, 63, 47], siguen siendo limitados en volumen de datos, calidad y diversidad de tareas. Para abordar estas limitaciones, construimos OnlineIT, un dataset de entrenamiento diseñado específicamente para streaming video understanding. OnlineIT se enfoca en comprensión fina de eventos y comprensión espaciotemporal en tiempo real en escenarios de streaming, y mejora significativamente el rendimiento de los MLLMs en tareas de streaming video understanding.

OnlineIT-general. Con base en criterios de diversidad, longitud y dificultad, curamos y refinamos varios datasets existentes de alta calidad para fine-tuning en streaming video understanding [23, 60, 47]. A partir de ellos, desarrollamos además dos nuevos datasets que comprenden 32K instancias de entrenamiento de streaming de alta calidad. Este dataset presenta mayor escala, distribución más amplia y mayor diversidad de tareas, facilitando el aprendizaje de representaciones de streaming video más generalizables.

OnlineIT-drive. Incluye 89K instancias de entrenamiento de streaming QA provenientes de escenarios de conducción autónoma. Este dataset está diseñado para mejorar el rendimiento de los MLLMs en tareas downstream complejas y en tiempo real. En particular, al integrar semántica de escena, regulaciones de tránsito y eventos comunes de conducción, extraemos elementos clave de escenas y clips de video de conducción para generar un dataset de preguntas y respuestas fundamentado en contextos de conducción autónoma. OnlineIT-Drive cubre principalmente cuatro áreas: (1) localización en tiempo real y conciencia semántica, (2) comprensión de entidades de tránsito estáticas, (3) comprensión de entidades de tránsito dinámicas y (4) evaluación de eventos de riesgo y accidentes.

4 ODV-Bench

Muchos benchmarks existentes para escenarios de streaming derivan de datasets de evaluación de video offline [39, 23, 36, 61], y pueden no reflejar adecuadamente aplicaciones reales de streaming video understanding. Aunque algunos de ellos ya incorporan videos Ego4D de actividades cotidianas [36, 61], estas muestras de evaluación evalúan principalmente la capacidad de los MLLMs para percibir escenas estáticas y narrar interacciones humano-entorno de manera secuencial. En contraste, la conducción autónoma presenta entornos dinámicos de alta exigencia con escenas que cambian rápidamente, interacciones complejas entre múltiples agentes (vehículos, peatones y señales de tránsito) y tareas de predicción demandantes (como evaluación de riesgo y planificación de movimiento). Estos escenarios requieren que los modelos equilibren memoria de largo plazo de eventos con percepción fina de corto plazo para evitar accidentes y tomar decisiones oportunas. Para abordar esta brecha, introducimos ODV-Bench, un benchmark diseñado específicamente para online video understanding en escenarios de conducción autónoma.

4.1 Formulación de tareas

Como se muestra en la Figura 3 (a), primero exploramos los elementos clave del tránsito en escenarios de conducción autónoma y los resumimos en tres categorías de escenarios de tarea: **(1) tareas orientadas a objetivos estáticos**, que involucran el reconocimiento y la recuperación de elementos de tránsito estacionarios como señales, semáforos e indicadores viales; **(2) tareas orientadas a objetivos dinámicos**, que se enfocan en la predicción de comportamiento y trayectoria de participantes dinámicos de la vía como vehículos y peatones; y **(3) tareas orientadas a eventos para interacción multiagente**, que capturan interacciones complejas, escenarios de riesgo y accidentes que involucran múltiples agentes. Luego, guiados por señales temporales y por las necesidades prácticas de la conducción, definimos además tipos de tareas finas basadas en estas categorías para evaluar de forma integral la comprensión del modelo en escenarios realistas de video de conducción online. Para más detalles sobre la formulación de tareas, véase el Apéndice C.1.




Figure 3: (a) The distribution of task types and the number of QA pairs. (b) The detailed pipeline for constructing the ODV-Bench. (c) Typical task examples in ODV-Bench.

4.2 Construcción del benchmark

El proceso de construcción de ODV-Bench se ilustra en la Figura 3 (b). Adoptamos un enfoque de cuatro etapas para garantizar la calidad de cada pregunta generada, y luego presentamos algunos ejemplos típicos de tareas en distintos escenarios de conducción en la Figura 3 (c).

Recolección de datos. (1) Selección de videos. Para alinearnos con escenarios de conducción del mundo real, primero curamos 6 datasets [24, 14, 82, 66, 73, 4] provenientes de distintos escenarios de tarea dentro del dominio de la conducción autónoma, desde conducción normal hasta eventos inesperados. Luego diseñamos una tubería semiautomática que se apoya principalmente en filtrado de anotaciones y detección basada en YOLO [25], complementada con inspección manual, para seleccionar videos relevantes para la tarea del dataset recolectado. **(2) Generación de meta-anotaciones.** Para obtener meta-anotaciones con información espaciotemporal y semántica detallada, desarrollamos métodos a medida basados en anotaciones existentes de los datasets. Para datasets bien anotados, convertimos eficazmente las etiquetas existentes en meta-anotaciones específicas de la tarea. Para los demás, diseñamos una tubería semiautomática que comienza con anotaciones gruesas generadas por VLLM y YOLO [25], seguidas por verificación humana estructurada para garantizar calidad.

Construcción de QA. (1) Generación de MCQ. Para habilitar generación automática eficiente de QA, primero diseñamos plantillas precisas y diversas adaptadas a cada tarea definida. Estas plantillas se completan luego con anotaciones finas y precisas para generar pares QA de alta calidad. Después desarrollamos una tubería de generación de múltiple opción basada en un conjunto de opciones, introduciendo distractores plausibles pero engañosos junto con la respuesta correcta para asegurar el realismo y la efectividad de las opciones. **(2) Control de calidad.** Para garantizar la calidad del benchmark, primero realizamos múltiples rondas de revisión manual para verificar la claridad y exactitud de los pares QA y la plausibilidad de las opciones distractoras. Además, para mejorar la diversidad de escenas y el equilibrio entre tipos de tareas, aplicamos una estrategia de muestreo que asigna preguntas proporcionalmente a la longitud del video, maximizando la cobertura entre escenarios.

5 Experimentos

Detalles de implementación. Adoptamos SigLiP-so400M[70] como visual encoder, usamos un MLP como projection head y empleamos Qwen2-7B como LLM. Por defecto, la cantidad de visual tokens está limitada a 8192. Entre ellos, 729 tokens se asignan a percepción en tiempo real, mientras que la memoria espaciotemporal de corto plazo consiste en 18 frames, cada uno representado por 128 visual tokens. Fijamos los pesos de penalización para similitud, conteo de fusiones y distancia temporal en 0.4, 0.4 y 0.2, respectivamente. El modelo se entrena en 32 GPUs A100 usando nuestro dataset propuesto OnlineIT, complementado con datos de video offline de VideoChat-Flash [33] y LLaVA-Video [76], así como con datos de imagen de LLaVA-OneVision [28]. Adoptamos una estrategia de entrenamiento de cinco etapas para entrenar StreamForest desde cero. Las primeras tres etapas siguen el paradigma de entrenamiento de MLLMs offline para video largo [33]. La cuarta etapa realiza fine-tuning de streaming video para obtener StreamForest base. Además, puede incorporarse una quinta etapa opcional entrenando con OnlineIT-Drive, lo que produce StreamForest(FT-drive).

Table 1: **Evaluation results on ODV-Bench.** Our model significantly outperforms state-of-the-art of-line and online video MLLMs under zero-shot testing conditions, and achieves further improvements after fine-tuning on driving-domain data.

Method	Size	#Frames	Static Target							Dynamic Target				Event Oriented				Overall
			RTP	HD	KIE	TCD	DDM	PTM	Avg.	AP	LP	DP	Avg.	RP	RA	ARA	Avg.	
Human																		
Human Agents	-	-	96.8	97.6	98.2	95.7	95.9	94.4	95.9	83.7	87.9	90.4	88.2	91.9	94.9	93.0	92.5	91.4
Open-source Offline Video MLLMs																		
MiniCPM-V2.6 [65]	7B	64	20.0	87.8	15.1	49.1	26.4	20.6	27.3	71.2	73.4	47.2	60.0	73.4	33.3	16.7	53.6	49.8
LongVA [75]	7B	64	29.9	7.3	37.7	47.3	38.0	33.6	31.8	66.6	58.6	50.9	56.6	57.5	58.1	46.2	56.7	50.2
LLaVA-Onevision [28]	7B	64	36.0	4.9	22.6	60.0	31.4	39.0	34.2	53.6	70.3	47.4	55.1	57.9	72.2	47.4	62.2	51.6
InternVL2.5 [8]	8B	32	40.1	16.3	37.7	52.7	30.4	40.9	37.2	64.1	84.6	49.5	62.5	54.0	60.6	50.6	56.1	54.2
VideoChat-Flash [33]	7B	256	29.6	15.5	45.3	76.4	26.1	36.1	32.2	73.5	75.3	47.2	61.0	67.1	64.8	46.2	64.3	54.4
Qwen2.5-VL [2]	7B	1fps	51.8	8.1	79.3	49.1	36.0	57.3	48.3	50.4	82.6	46.9	57.5	47.6	78.6	52.6	59.4	55.6
Open-source Online Video MLLMs																		
Flash-VStream [72]	7B	1fps	25.4	1.6	11.3	50.9	36.0	22.1	24.8	25.5	39.8	47.2	40.2	32.4	48.6	30.1	38.1	35.7
Dispider [47]	7B	1fps	31.1	7.3	34.0	63.6	34.0	35.4	32.5	43.2	73.1	45.8	52.7	38.2	55.4	36.5	44.3	45.2
VideoChat-Online [23]	4B	1fps	36.9	0.8	62.3	49.1	21.5	47.0	36.1	70.2	86.7	46.4	62.9	51.2	69.4	45.5	57.4	54.5
StreamForest	7B	1fps	51.4	15.5	54.7	56.4	38.6	65.3	51.5	72.6	83.2	46.0	62.3	60.2	73.3	47.4	63.8	59.9
StreamForest (FT-drive)	7B	1fps	70.1	17.1	100.0	60.0	32.7	83.6	64.6	64.0	96.6	59.6	70.7	71.8	93.4	58.3	78.5	71.2

Durante la fase de evaluación, restringimos al modelo a procesar frames de streaming a 1 FPS. Para detalles de implementación más específicos, véase el Apéndice D.

5.1 Resultados en benchmarks online

Evaluamos el rendimiento de nuestro modelo en cuatro benchmarks de online video question answering: ODV-Bench, StreamingBench [39], OVBench [23] y OVO-Bench [36]. Estos benchmarks siguen escenarios de streaming video QA, donde los VideoLLMs deben procesar únicamente el contenido de video disponible antes del timestamp actual.

ODV-Bench. Integra estrechamente información espaciotemporal para evaluar de forma integral la capacidad de los MLLMs para comprender detalles finos en videos online y realizar predicciones futuras basadas tanto en contexto histórico como actual en escenarios de conducción autónoma. El benchmark incluye tareas como identificar objetos o acciones sutiles, describir posiciones de objetos y relaciones espaciales, y predecir trayectorias de objetos. Estas tareas requieren una sólida percepción espaciotemporal en tiempo real y comprensión contextual. Como se muestra en la Tabla 1, StreamForest alcanza una exactitud promedio de 59.9% en ODV-Bench sin ser entrenado con OnlineIT-drive y mejora aún más hasta 71.2% después de entrenarse con él. Esto supera significativamente a todos los MLLMs online y offline existentes, demostrando la fuerte capacidad de generalización de nuestro método hacia tareas downstream de streaming video understanding. Estos resultados resaltan su potencial para aplicaciones del mundo real.

StreamingBench & OVBench & OVO-Bench. Como se muestra en la Tabla 2, StreamForest demuestra un rendimiento sólido en los benchmarks open-source existentes de streaming video understanding. Alcanza una exactitud de 77.3% en StreamingBench, 60.5% en OVBench y 55.6% en OVO-Bench. Estos resultados destacados subrayan la robustez de StreamForest en una amplia gama de escenarios de online video understanding. El rendimiento superior de nuestro modelo puede atribuirse a dos innovaciones arquitectónicas clave. Primero, la Fine-grained Spatiotemporal Window permite percepción espacial precisa y modelado temporal reactivo de corto plazo, ambos críticos para tareas de percepción en tiempo real y respuesta hacia adelante. Segundo, el Persistent Event Memory Forest organiza adaptativamente contenido visual de largo plazo en un bosque de memoria estructurado y eficiente, mejorando significativamente la capacidad del MLLM para retener y razonar sobre eventos pasados. En conjunto, estos dos módulos ofrecen capacidades complementarias que permiten a nuestro modelo manejar eficazmente entradas dinámicas de streaming video de largo horizonte, manteniendo al mismo tiempo alta coherencia contextual.

Table 2: **Comparison of our method with existing approaches on video question answering tasks across various scenarios.** Our approach significantly outperforms previous methods on streaming video understanding benchmarks, while maintaining strong and competitive performance on both long and short video understanding.

Method	Size	Online Video			Long Video		Short Video	
		StreamingBench	OVBench	OVO-Bench	VideoMME	MLVU	MVBench	PerceptionTest
		Real-Time All	Avg	Overall	w/o sub.	M-Avg	Avg	Val
Open-source Offline Video MLLMs								
InternVL2 [9]	8B	63.7	48.7	50.1	54.0	64.0	65.8	-
LongVA [75]	7B	60.0	43.6	-	52.6	56.3	-	-
LLaVA-OneVision [28]	7B	71.1	49.5	52.9	58.2	64.7	56.7	57.1
Qwen2-VL [55]	7B	69.0	49.7	52.7	63.3	-	67.0	66.9
LongVU [50]	7B	-	-	48.5	60.6	65.4	66.9	-
LLaVA-Video [76]	7B	-	-	53.1	63.3	70.8	58.6	67.9
Open-source Online Video MLLMs								
VideoLLM-online [5]	8B	36.0	9.6	12.8	-	-	-	-
MovieChat [52]	7B	-	30.9	-	38.2	-	55.1	-
Flash-VStream [72]	7B	23.2	31.2	33.2	-	-	-	-
VideoChat-Online [23]	4B	-	54.9	-	52.8	-	64.9	-
Dispider [47]	7B	67.6	-	41.8	57.2	61.7	-	-
StreamForest	7B	77.3	60.5	55.6	61.4	70.0	70.2	73.1
StreamForest (FT-drive)	7B	76.8	61.6	55.6	61.9	69.6	68.6	71.6

5.2 Resultados en benchmarks offline

Además evaluamos nuestro método en dos benchmarks de long video understanding (VideoMME[16] y MLVU[77]) y dos datasets de video corto (MVBench[31] y PerceptionTest[45]). En el escenario offline, el video completo se proporciona como entrada al MLLM. Muestreamos frames de video a 1 FPS, con un límite máximo de 2048 frames. Para los videos que exceden este límite, los frames se muestrean uniformemente a lo largo de toda la duración. Como se muestra en la Tabla 2, nuestro método demuestra un rendimiento superior tanto en tareas de video understanding largo como corto en comparación con los recientes online Video MLLMs de estado del arte. Además, supera a modelos offline líderes en la mayoría de los benchmarks, logrando 61.4% en VideoMME, 70.0% en MLVU, 70.2% en MVBench y 73.1% en PerceptionTest. Este sólido rendimiento en escenarios offline resalta la robusta capacidad de generalización de nuestro método propuesto.

5.3 Ablaciones

Efectividad de Persistent Event Memory Forest: Reemplazamos el PEMF propuesto por varios métodos usados en trabajos previos. Para asegurar una comparación justa, mantenemos consistentes los presupuestos de visual tokens en todos los métodos y realizamos fine-tuning de cada modelo en consecuencia. Los resultados de ablación se muestran en la Tabla 3. La estrategia FIFO muestra el peor rendimiento. Esto es especialmente evidente en el benchmark de video largo MLVU (56.7% vs. 70.0%), donde el método falla debido al descarte sin filtrado de características visuales históricas. OVBench enfatiza principalmente percepción espaciotemporal fina y de corto plazo. El muestreo uniforme reduce la resolución de la información visual reciente, que es crucial para la comprensión en tiempo real (58.2% vs. 60.5% en OVBench). Similarity Merge logra un rendimiento comparable al de nuestro PEMF en OVBench (60.3% vs. 60.5%). Sin embargo, sus limitaciones se vuelven claras en tareas que requieren memoria persistente y razonamiento de largo horizonte. En OVO-Bench, PEMF supera a Similarity Merge en +2.2%, y en MLVU en +2.0%. Esto se debe a que la fusión basada en similitud puede fusionar en exceso frames dentro de segmentos locales de video, lo que podría conducir a irregularidades espaciotemporales y a la pérdida de representaciones locales a nivel de evento. El pyramidal memory bank mantiene memoria mediante reemplazo de frames. Sin embargo, la capacidad fija limita su habilidad para capturar características espaciotemporales de largo alcance (53.9% vs. 55.6% en OVO-Bench y 68.2% vs. 70.0 en MLVU). En contraste, nuestro método evalúa cada evento visual según similitud a nivel de evento, conteo de fusiones y distancia temporal. Luego realiza consolidación de memoria a nivel de evento. Esta estrategia soporta un mantenimiento eficiente y persistente de características visuales históricas.

Table 3: Comparison between our proposed PEMF and other commonly used memory strategies.

Memory Policy	OVBench	OVO-Bench	MLVU
	Avg	Overall	M-Avg
Uniform Sampling	58.2	52.7	69.4
First In First Out	58.7	52.9	56.7
Similarity Merge [52]	60.3	53.4	68.0
Pyramid Memory Bank [23]	60.3	53.9	68.2
PEMF (Ours)	60.5	55.6	70.0

Table 4: Ablation study on the key components of StreamForest.

Model	OVBench	OVO-Bench	MLVU
	Avg	Overall	M-Avg
w/o FSTW & PEMF	58.0	52.5	51.8
w/o FSTW	59.1	53.7	69.4
w/o PEMF	58.9	53.5	56.6
w/o Event	59.4	52.6	69.1
Ours	60.5	55.6	70.0

Efectividad de la arquitectura completa: Realizamos estudios de ablación sobre tres componentes arquitectónicos clave. En particular, ablatimos la Fine-grained Spatiotemporal Window y el Persistent Event Memory Forest, garantizando al mismo tiempo que el número total de visual tokens se mantenga consistente con la configuración original. Además, reemplazamos la construcción de nodos basada en eventos por un enfoque basado en frames. Como se muestra en la Tabla 4, eliminar ambos módulos conduce a la caída de rendimiento más significativa. Usar solo FSTW o solo PEMF mejora el rendimiento en comparación con el baseline, pero los mejores resultados se logran cuando ambos componentes se integran (+2.5% en OVBench, +3.1% en OVO-Bench y +18.2% en MLVU). Esta ablación conjunta confirma que FSTW y PEMF proporcionan beneficios complementarios. FSTW mejora la percepción espaciotemporal en tiempo real cerca del timestamp de la consulta, mientras que PEMF soporta una memoria de largo plazo eficiente y persistente, produciendo juntos el rendimiento global más fuerte. Además, la construcción de nodos a nivel de evento previene eficazmente la sobre-fusión dentro de los eventos, permitiendo comprimir características visuales al nivel de eventos visuales completos en lugar de frames individuales.




Figure 4: Performance under varying visual token budgets.




Figure 5: Average inference time under varying visual token budgets (on single A100 GPU).

Robustez ante distintos presupuestos de visual tokens: Evaluamos la robustez de nuestro método bajo distintas restricciones presupuestarias para visual tokens, desde 1K hasta 10K. La Figura 4 ilustra la variación del rendimiento en los benchmarks MLVU, VideoMME y OVO-Bench bajo estas configuraciones. Notablemente, bajo la restricción estricta de solo 1K visual tokens, StreamForest alcanza una tasa promedio de compresión visual de hasta 99.8% en benchmarks de video largo. A pesar de este nivel extremo de compresión, el modelo aún mantiene un rendimiento competitivo, lo que demuestra con fuerza la robustez de nuestro enfoque para preservar persistentemente memorias visuales de largo plazo a nivel de evento. También realizamos una comparación directa entre nuestro PEMF y Similarity Merge. Los resultados demuestran claramente dos beneficios centrales de nuestro enfoque. Primero, PEMF exhibe un rendimiento absoluto superior, superando consistentemente a Similarity Merge en todos los presupuestos de tokens con una mejora promedio de exactitud de 2–3%. Segundo, nuestro método muestra mayor resiliencia frente a compresión extrema. Bajo el presupuesto más severo de 1K tokens, PEMF retiene una fracción más alta de su rendimiento con presupuesto completo, logrando una ventaja relativa notable de retención de +1.8% en VideoMME. Estos resultados experimentales confirman que las ganancias de rendimiento provienen del diseño intrínseco de PEMF, que consolida adaptativamente memoria a nivel de evento para preservar información semánticamente saliente, asegurando así tanto alta exactitud como eficiencia de tokens bajo restricciones estrictas de recursos. La Figura 5 presenta el tiempo promedio de inferencia de

Table 5: Quantitative analysis of runtime and memory usage of StreamForest.

Input Frames	Memory (GB)	FLOPs (T)	Latency (s)
64	15.8	93.1	0.776
256	17.1	134.1	1.126
1024	17.2	137.3	1.497

Table 6: Runtime comparison of PEMF with other memory mechanisms for 500 frames.

Method	Vis. Encode (s)	Mem. Update (s)	LLM infer (s)	Total (s)
Similarity Merge [52]	5.198	0.183	1.388	6.769
PMB [23]	5.203	0.451	1.381	7.035
PEMF (Ours)	5.218	0.172	1.394	6.784

StreamForest bajo distintos presupuestos de visual tokens. La velocidad de inferencia rápida y estable resalta la aplicabilidad práctica de StreamForest.

Costo computacional: Proporcionamos un análisis cuantitativo del tiempo de ejecución y el uso de memoria de StreamForest. Para aislar el efecto del mecanismo de memoria, asumimos que las características visuales a nivel de frame ya han sido extraídas por el vision encoder en tiempo real. Como se muestra en la Tabla 5, PEMF impone un límite superior estricto de visual tokens (8K aquí), garantizando que el uso de memoria permanezca estable (17 GB) independientemente del número de frames procesados. En consecuencia, los FLOPs y la latencia de inferencia no crecen significativamente incluso con entradas de streaming más largas. Además, comparamos PEMF con otros mecanismos de memoria, incluyendo Pyramid Memory Bank [23] y la estrategia Similarity Merge [52]. Como se resume en la Tabla 6, el tiempo total de ejecución está dominado por el vision encoding (5.2s para 500 frames, ~ 95 FPS). La actualización de memoria de PEMF es extremadamente ligera (0.172s para 500 frames), lo cual es despreciable en comparación con las ganancias de eficiencia obtenidas al reducir significativamente la cantidad total de visual tokens.

Impacto de los datos de entrenamiento: La Tabla 7 presenta el impacto de nuestra estrategia de entrenamiento que integra tanto datasets online como offline. Los resultados demuestran claramente que combinar OnlineIT con datasets existentes de offline VideoQA mejora significativamente el rendimiento en benchmarks de streaming video understanding. OnlineIT está diseñado específicamente para percepción en tiempo real y predicción futura en escenarios de streaming, mitigando eficazmente las alucinaciones causadas por inconsistencias entre el contexto espaciotemporal histórico y el momento actual.

Table 7: The contribution of our training data to performance on the streaming video understanding benchmark. O.general refers to OnlineIT-general, while O.drive refers to OnlineIT-drive.

Data	ODV-Bench	OV-Bench	OVO-Bench
	Avg	Avg	Overall
base	56.3	53.9	53.5
base + O.general	59.9	60.5	55.6
base + O.general + O.drive	71.2	61.6	55.6

6 Conclusiones

En este trabajo hemos propuesto StreamForest, una arquitectura novedosa para streaming video understanding que aborda las limitaciones en memoria de largo plazo y percepción fina. Al introducir Persistent Event Memory Forest, nuestro método gestiona eficazmente la información visual histórica mediante una fusión adaptativa guiada por penalizaciones de distancia temporal, similitud de contenido y conteo de fusiones. Acoplado con Fine-grained Spatiotemporal Window, el modelo mantiene una comprensión precisa de la escena actual. También presentamos OnlineIT, un dataset de fine-tuning para streaming video understanding que mitiga problemas de desplazamiento espaciotemporal y mejora la percepción y el razonamiento en tiempo real, así como ODV-Bench, un nuevo benchmark adaptado a escenarios de conducción autónoma en tiempo real. Experimentos extensivos demuestran que StreamForest no solo supera a los streaming video MLLMs de estado del arte, sino que también compite con los principales offline video MLLMs bajo configuraciones estrictas de entrada en streaming, mostrando su robustez y valor práctico en aplicaciones de streaming video understanding en tiempo real.

Acknowledgement

This work is supported by the National Key R&D Program of China (No. 2022ZD0160900), the Natural Science Foundation of Jiangsu Province (No. BK20250009), and the Collaborative Innovation Center of Novel Software Technology and Industrialization.

References

- [1] Anthropic. Claude 3.5 sonnet, 2024. URL <https://www.anthropic.com/news/claude-3-5-sonnet>.
- [2] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, et al. Qwen2. 5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025.
- [3] Daniel Bolya, Cheng-Yang Fu, Xiaoliang Dai, Peizhao Zhang, Christoph Feichtenhofer, and Judy Hoffman. Token merging: Your vit but faster. *arXiv preprint arXiv:2210.09461*, 2022.
- [4] Zhengping Che, Guangyu Li, Tracy Li, Bo Jiang, Xuefeng Shi, Xinsheng Zhang, Ying Lu, Guobin Wu, Yan Liu, and Jieping Ye. D²-city: a large-scale dashcam video dataset of diverse traffic scenarios. *arXiv preprint arXiv:1904.01975*, 2019.
- [5] Joya Chen, Zhaoyang Lv, Shiwei Wu, Kevin Qinghong Lin, Chenan Song, Difei Gao, Jia-Wei Liu, Ziteng Gao, Dongxing Mao, and Mike Zheng Shou. Videollm-online: Online video large language model for streaming video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 18407–18418, 2024.
- [6] Joya Chen, Ziyun Zeng, Yiqi Lin, Wei Li, Zejun Ma, and Mike Zheng Shou. Livecc: Learning video llm with streaming speech transcription at scale. *arXiv preprint arXiv:2504.16030*, 2025.
- [7] Yukang Chen, Fuzhao Xue, Dacheng Li, Qinghao Hu, Ligeng Zhu, Xiuyu Li, Yunhao Fang, Haotian Tang, Shang Yang, Zhijian Liu, et al. Longvila: Scaling long-context visual language models for long videos. *arXiv preprint arXiv:2408.10188*, 2024.
- [8] Zhe Chen, Weiyun Wang, Yue Cao, Yangzhou Liu, Zhangwei Gao, Erfei Cui, Jinguo Zhu, Shenglong Ye, Hao Tian, Zhaoyang Liu, et al. Expanding performance boundaries of open-source multimodal models with model, data, and test-time scaling. *arXiv preprint arXiv:2412.05271*, 2024.
- [9] Zhe Chen, Weiyun Wang, Hao Tian, Shenglong Ye, Zhangwei Gao, Erfei Cui, Wenwen Tong, Kongzhi Hu, Jiapeng Luo, Zheng Ma, et al. How far are we to gpt-4v? closing the gap to commercial multimodal models with open-source suites. *Science China Information Sciences*, 67(12):220101, 2024.
- [10] Zesen Cheng, Sicong Leng, Hang Zhang, Yifei Xin, Xin Li, Guanzheng Chen, Yongxin Zhu, Wenqi Zhang, Ziyang Luo, Deli Zhao, et al. Videollama 2: Advancing spatial-temporal modeling and audio understanding in video-llms. *arXiv preprint arXiv:2406.07476*, 2024.
- [11] Shangzhe Di, Zhelun Yu, Guanghao Zhang, Haoyuan Li, Tao Zhong, Hao Cheng, Bolin Li, Wanggui He, Fangxun Shu, and Hao Jiang. Streaming video question-answering with in-context video kv-cache retrieval. *arXiv preprint arXiv:2503.00540*, 2025.
- [12] Xin Ding, Hao Wu, Yifan Yang, Shiqi Jiang, Donglin Bai, Zhibo Chen, and Ting Cao. Streammind: Unlocking full frame rate streaming video dialogue through event-gated cognition. *arXiv preprint arXiv:2503.06220*, 2025.
- [13] Heng Fan, Liting Lin, Fan Yang, Peng Chu, Ge Deng, Sijia Yu, Hexin Bai, Yong Xu, Chunyuan Liao, and Haibin Ling. Lasot: A high-quality benchmark for large-scale single object tracking. In *CVPR*, pages 5374–5383, 2019.
- [14] Jianwu Fang, Lei-lei Li, Junfei Zhou, Junbin Xiao, Hongkai Yu, Chen Lv, Jianru Xue, and Tat-Seng Chua. Abductive ego-view accident video understanding for safe driving perception. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 22030–22040, 2024.
- [15] Jiajun Fei, Dian Li, Zhidong Deng, Zekun Wang, Gang Liu, and Hui Wang. Video-ccam: Enhancing video-language understanding with causal cross-attention masks for short and long videos. *arXiv preprint arXiv:2408.14023*, 2024.
- [16] Chaoyou Fu, Yuhao Dai, Yongdong Luo, Lei Li, Shuhuai Ren, Renrui Zhang, Zihan Wang, Chenyu Zhou, Yunhang Shen, Mengdan Zhang, et al. Video-mme: The first-ever comprehensive evaluation benchmark of multi-modal llms in video analysis. *arXiv preprint arXiv:2405.21075*, 2024.

- [17] Jiyang Gao, Chen Sun, Zhenheng Yang, and Ram Nevatia. Tall: Temporal activity localization via language query. In *ICCV*, pages 5267–5275, 2017.
- [18] Chunhui Gu, Chen Sun, Sudheendra Vijayanarasimhan, Caroline Pantofaru, David A. Ross, George Toderici, Yeqing Li, Susanna Ricco, Rahul Sukthankar, Cordelia Schmid, and Jitendra Malik. Ava: A video dataset of spatio-temporally localized atomic visual actions. *CVPR*, 2017.
- [19] Bin Huang, Xin Wang, Hong Chen, Zihan Song, and Wenwu Zhu. Vtimellm: Empower llm to grasp video moments. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14271–14280, 2024.
- [20] De-An Huang, Shijia Liao, Subhashree Radhakrishnan, Hongxu Yin, Pavlo Molchanov, Zhiding Yu, and Jan Kautz. Lita: Language instructed temporal-localization assistant. In *European Conference on Computer Vision*, pages 202–218. Springer, 2024.
- [21] Gabriel Huang, Bo Pang, Zhenhai Zhu, Clara Rivera, and Radu Soricut. Multimodal pretraining for dense video captioning. In Kam-Fai Wong, Kevin Knight, and Hua Wu, editors, *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, December 2020.
- [22] Lianghua Huang, Xin Zhao, and Kaiqi Huang. Got-10k: A large high-diversity benchmark for generic object tracking in the wild. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(5): 1562–1577, 2021. doi: 10.1109/TPAMI.2019.2957464.
- [23] Zhenpeng Huang, Xinhao Li, Jiaqi Li, Jing Wang, Xiangyu Zeng, Cheng Liang, Tao Wu, Xi Chen, Liang Li, and Limin Wang. Online video understanding: Ovbench and videochat-online. In *CVPR*, pages 3328–3338, 2025.
- [24] Salman Khan, Izzeddin Teeti, Reza Javanmard Alitappeh, Mihaela C Stoian, Eleonora Giunchiglia, Gurkirt Singh, Andrew Bradley, and Fabio Cuzzolin. Road-waymo: Action awareness at scale for autonomous driving. *arXiv preprint arXiv:2411.01683*, 2024.
- [25] Rahima Khanam and Muhammad Hussain. Yolov11: An overview of the key architectural enhancements. *arXiv preprint arXiv:2410.17725*, 2024.
- [26] Ranjay Krishna, Kenji Hata, Frederic Ren, Li Fei-Fei, and Juan Carlos Niebles. Dense-captioning events in videos. In *ICCV*, 2017.
- [27] Ranjay Krishna, Yuke Zhu, Oliver Groth, Justin Johnson, Kenji Hata, Joshua Kravitz, Stephanie Chen, Yannis Kalantidis, Li-Jia Li, David A Shamma, et al. Visual genome: Connecting language and vision using crowdsourced dense image annotations. *IJCV*, 123:32–73, 2017.
- [28] Bo Li, Yuanhan Zhang, Dong Guo, Renrui Zhang, Feng Li, Hao Zhang, Kaichen Zhang, Peiyuan Zhang, Yanwei Li, Ziwei Liu, et al. Llava-onevision: Easy visual task transfer. *arXiv preprint arXiv:2408.03326*, 2024.
- [29] Hongyu Li, Jinyu Chen, Ziyu Wei, Shaoifei Huang, Tianrui Hui, Jialin Gao, Xiaoming Wei, and Si Liu. Llava-st: A multimodal large language model for fine-grained spatial-temporal understanding. *arXiv preprint arXiv:2501.08282*, 2025.
- [30] KunChang Li, Yinan He, Yi Wang, Yizhuo Li, Wenhai Wang, Ping Luo, Yali Wang, Limin Wang, and Yu Qiao. Videochat: Chat-centric video understanding. *arXiv preprint arXiv:2305.06355*, 2023.
- [31] Kunchang Li, Yali Wang, Yinan He, Yizhuo Li, Yi Wang, Yi Liu, Zun Wang, Jilan Xu, Guo Chen, Ping Luo, et al. Mvbench: A comprehensive multi-modal video understanding benchmark. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 22195–22206, 2024.
- [32] Wei Li, Bing Hu, Rui Shao, Leyang Shen, and Liqiang Nie. Lion-fs: Fast & slow video-language thinker as online video assistant. *arXiv preprint arXiv:2503.03663*, 2025.
- [33] Xinhao Li, Yi Wang, Jiashuo Yu, Xiangyu Zeng, Yuhan Zhu, Haian Huang, Jianfei Gao, Kunchang Li, Yinan He, Chenting Wang, et al. Videochat-flash: Hierarchical compression for long-context video modeling. *arXiv preprint arXiv:2501.00574*, 2024.
- [34] Xinhao Li, Ziang Yan, Desen Meng, Lu Dong, Xiangyu Zeng, Yinan He, Yali Wang, Yu Qiao, Yi Wang, and Limin Wang. Videochat-r1: Enhancing spatio-temporal perception via reinforcement fine-tuning. *arXiv preprint arXiv:2504.06958*, 2025.

- [35] Yanwei Li, Chengyao Wang, and Jiaya Jia. Llama-vid: An image is worth 2 tokens in large language models. In *European Conference on Computer Vision*, pages 323–340. Springer, 2024.
- [36] Yifei Li, Junbo Niu, Ziyang Miao, Chunjiang Ge, Yuanhang Zhou, Qihao He, Xiaoyi Dong, Haodong Duan, Shuangrui Ding, Rui Qian, et al. Ovo-bench: How far is your video-llms from real-world online video understanding? *arXiv preprint arXiv:2501.05510*, 2025.
- [37] Bin Lin, Yang Ye, Bin Zhu, Jiayi Cui, Munan Ning, Peng Jin, and Li Yuan. Video-llava: Learning united visual representation by alignment before projection. *arXiv preprint arXiv:2311.10122*, 2023.
- [38] Ji Lin, Hongxu Yin, Wei Ping, Pavlo Molchanov, Mohammad Shoeybi, and Song Han. Vila: On pre-training for visual language models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 26689–26699, 2024.
- [39] Junming Lin, Zheng Fang, Chi Chen, Zihao Wan, Fuwen Luo, Peng Li, Yang Liu, and Maosong Sun. Streamingbench: Assessing the gap for mllms to achieve streaming video understanding. *arXiv preprint arXiv:2411.03628*, 2024.
- [40] Jiajun Liu, Yibing Wang, Hanghang Ma, Xiaoping Wu, Xiaoqi Ma, Xiaoming Wei, Jianbin Jiao, Enhua Wu, and Jie Hu. Kangaroo: A powerful video-language model supporting long-context video input. *arXiv preprint arXiv:2408.15542*, 2024.
- [41] Zhijian Liu, Ligeng Zhu, Baifeng Shi, Zhuoyang Zhang, Yuming Lou, Shang Yang, Haocheng Xi, Shiyi Cao, Yuxian Gu, Dacheng Li, et al. Nvila: Efficient frontier visual language models. *arXiv preprint arXiv:2412.04468*, 2024.
- [42] Zuyan Liu, Yuhao Dong, Ziwei Liu, Winston Hu, Jiwen Lu, and Yongming Rao. Oryx mllm: On-demand spatial-temporal understanding at arbitrary resolution. *arXiv preprint arXiv:2409.12961*, 2024.
- [43] Andreea-Maria Oncescu, Joao F Henriques, Yang Liu, Andrew Zisserman, and Samuel Albanie. Queryd: A video dataset with high-quality text and audio narrations. In *ICASSP*, pages 2265–2269. IEEE, 2021.
- [44] OpenAI. Hello gpt-4o. <https://openai.com/index/hello-gpt-4o>, 2024.
- [45] Viorica Pătrăucean, Lucas Smaira, Ankush Gupta, Adrià Recasens Contente, Larisa Markeeva, Dylan Banarse, Skanda Koppula, Joseph Heyward, Mateusz Malinowski, Yi Yang, Carl Doersch, Tatiana Matejovicova, Yury Sulsky, Antoine Miech, Alex Frechette, Hanna Klimczak, Raphael Koster, Junlin Zhang, Stephanie Winkler, Yusuf Aytar, Simon Osindero, Dima Damen, Andrew Zisserman, and João Carreira. Perception test: A diagnostic benchmark for multimodal video models. In *Advances in Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=HYEGXFnPoq>.
- [46] Rui Qian, Xiaoyi Dong, Pan Zhang, Yuhang Zang, Shuangrui Ding, Dahua Lin, and Jiaqi Wang. Streaming long video understanding with large language models. *Advances in Neural Information Processing Systems*, 37:119336–119360, 2024.
- [47] Rui Qian, Shuangrui Ding, Xiaoyi Dong, Pan Zhang, Yuhang Zang, Yuhang Cao, Dahua Lin, and Jiaqi Wang. Dispider: Enabling video llms with active real-time interaction via disentangled perception, decision, and reaction. *arXiv preprint arXiv:2501.03218*, 2025.
- [48] Shuhuai Ren, Linli Yao, Shicheng Li, Xu Sun, and Lu Hou. Timechat: A time-sensitive multimodal large language model for long video understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14313–14323, 2024.
- [49] Hao Shao, Yuxuan Hu, Letian Wang, Guanglu Song, Steven L Waslander, Yu Liu, and Hongsheng Li. Lmdrive: Closed-loop end-to-end driving with large language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15120–15130, 2024.
- [50] Xiaoqian Shen, Yunyang Xiong, Changsheng Zhao, Lemeng Wu, Jun Chen, Chenchen Zhu, Zechun Liu, Fanyi Xiao, Balakrishnan Varadarajan, Florian Bordes, et al. Longvu: Spatiotemporal adaptive compression for long video-language understanding. *arXiv preprint arXiv:2410.17434*, 2024.
- [51] Yan Shu, Zheng Liu, Peitian Zhang, Minghao Qin, Junjie Zhou, Zhengyang Liang, Tiejun Huang, and Bo Zhao. Video-xl: Extra-long vision language model for hour-scale video understanding. *arXiv preprint arXiv:2409.14485*, 2024.
- [52] Enxin Song, Wenhao Chai, Guanhong Wang, Yucheng Zhang, Haoyang Zhou, Feiyang Wu, Haozhe Chi, Xun Guo, Tian Ye, Yanting Zhang, et al. Moviechat: From dense token to sparse memory for long video understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 18221–18232, 2024.

- [53] Yansong Tang, Dajun Ding, Yongming Rao, Yu Zheng, Danyang Zhang, Lili Zhao, Jiwen Lu, and Jie Zhou. COIN: A large-scale dataset for comprehensive instructional video analysis. In *CVPR*, pages 1207–1216, 2019.
- [54] Gemini Team, Petko Georgiev, Ving Ian Lei, Ryan Burnell, Libin Bai, Anmol Gulati, Garrett Tanzer, Damien Vincent, Zhufeng Pan, Shibo Wang, et al. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. *arXiv preprint arXiv:2403.05530*, 2024.
- [55] Peng Wang, Shuai Bai, Sinan Tan, Shijie Wang, Zhihao Fan, Jinze Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, et al. Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*, 2024.
- [56] Weiyun Wang, Yiming Ren, Haowen Luo, Tiantong Li, Chenxiang Yan, Zhe Chen, Wenhui Wang, Qingyun Li, Lewei Lu, Xizhou Zhu, et al. The all-seeing project v2: Towards general relation comprehension of the open world. *arXiv preprint arXiv:2402.19474*, 2024.
- [57] Xidong Wang, Dingjie Song, Shunian Chen, Chen Zhang, and Benyou Wang. Longllava: Scaling multimodal llms to 1000 images efficiently via a hybrid architecture. *arXiv preprint arXiv:2409.02889*, 2024.
- [58] Yi Wang, Kunchang Li, Xinhao Li, Jiashuo Yu, Yinan He, Guo Chen, Baoqi Pei, Rongkun Zheng, Zun Wang, Yansong Shi, Tianxiang Jiang, Songze Li, Jilan Xu, Hongjie Zhang, Yifei Huang, Yu Qiao, Yali Wang, and Limin Wang. Internvideo2: Scaling foundation models for multimodal video understanding. In *ECCV*, pages 396–416, 2024.
- [59] Yi Wang, Xinhao Li, Ziang Yan, Yinan He, Jiashuo Yu, Xiangyu Zeng, Chenting Wang, Changlian Ma, Haihan Huang, Jianfei Gao, et al. Internvideo2. 5: Empowering video mllms with long and rich context modeling. *arXiv preprint arXiv:2501.12386*, 2025.
- [60] Yueqian Wang, Xiaojun Meng, Yuxuan Wang, Jianxin Liang, Jiansheng Wei, Huishuai Zhang, and Dongyan Zhao. Videollm knows when to speak: Enhancing time-sensitive video comprehension with video-text duet interaction format, 2024. URL <https://arxiv.org/abs/2411.17991>.
- [61] Haomiao Xiong, Zongxin Yang, Jiazuo Yu, Yunzhi Zhuge, Lu Zhang, Jiawen Zhu, and Huchuan Lu. Streaming video understanding and multi-round interaction with memory-enhanced knowledge. *arXiv preprint arXiv:2501.13468*, 2025.
- [62] Ziang Yan, Zhilin Li, Yinan He, Chenting Wang, Kunchang Li, Xinhao Li, Xiangyu Zeng, Zilei Wang, Yali Wang, Yu Qiao, et al. Task preference optimization: Improving multimodal large language models with vision task alignment. *arXiv preprint arXiv:2412.19326*, 2024.
- [63] Zhenyu Yang, Yuhang Hu, Zemin Du, Dizhan Xue, Shengsheng Qian, Jiahong Wu, Fan Yang, Weiming Dong, and Changsheng Xu. Svbench: A benchmark with temporal multi-turn dialogues for streaming video understanding. *arXiv preprint arXiv:2502.10810*, 2025.
- [64] Linli Yao, Yicheng Li, Yuancheng Wei, Lei Li, Shuhuai Ren, Yuanxin Liu, Kun Ouyang, Lean Wang, Shicheng Li, Sida Li, et al. Timechat-online: 80% visual tokens are naturally redundant in streaming videos. *arXiv preprint arXiv:2504.17343*, 2025.
- [65] Yuan Yao, Tianyu Yu, Ao Zhang, Chongyi Wang, Junbo Cui, Hongji Zhu, Tianchi Cai, Haoyu Li, Weilin Zhao, Zhihui He, et al. Minicpm-v: A gpt-4v level mllm on your phone. *arXiv preprint arXiv:2408.01800*, 2024.
- [66] Fisher Yu, Haofeng Chen, Xin Wang, Wenqi Xian, Yingying Chen, Fangchen Liu, Vashisht Madhavan, and Trevor Darrell. Bdd100k: A diverse driving dataset for heterogeneous multitask learning. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 2636–2645, 2020.
- [67] Licheng Yu, Patrick Poirson, Shan Yang, Alexander C Berg, and Tamara L Berg. Modeling context in referring expressions. In *ECCV*, pages 69–85. Springer, 2016.
- [68] Abhay Zala, Jaemin Cho, Satwik Kottur, Xilun Chen, Barlas Oguz, Yashar Mehdad, and Mohit Bansal. Hierarchical video-moment retrieval and step-captioning. In *CVPR*, pages 23056–23065, 2023.
- [69] Xiangyu Zeng, Kunchang Li, Chenting Wang, Xinhao Li, Tianxiang Jiang, Ziang Yan, Songze Li, Yansong Shi, Zhengrong Yue, Yi Wang, et al. Timesuite: Improving mllms for long video understanding via grounded tuning. *arXiv preprint arXiv:2410.19702*, 2024.
- [70] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 11975–11986, 2023.

- [71] Boqiang Zhang, Kehan Li, Zesen Cheng, Zhiqiang Hu, Yuqian Yuan, Guanzheng Chen, Sicong Leng, Yuming Jiang, Hang Zhang, Xin Li, et al. Videollama 3: Frontier multimodal foundation models for image and video understanding. *arXiv preprint arXiv:2501.13106*, 2025.
- [72] Haoji Zhang, Yiqin Wang, Yansong Tang, Yong Liu, Jiashi Feng, Jifeng Dai, and Xiaojie Jin. Flash-vstream: Memory-based real-time understanding for long video streams. *arXiv preprint arXiv:2406.08085*, 2024.
- [73] Jun-Bo Zhang, Wei Feng, Meng-Biao Zhao, Fei Yin, Xu-Yao Zhang, and Cheng-Lin Liu. Video text detection with robust feature representation. *IEEE Transactions on Circuits and Systems for Video Technology*, 34(6):4407–4420, 2023.
- [74] Pan Zhang, Xiaoyi Dong, Yuhang Cao, Yuhang Zang, Rui Qian, Xilin Wei, Lin Chen, Yifei Li, Junbo Niu, Shuangrui Ding, et al. Internlm-xcomposer2. 5-omnilive: A comprehensive multimodal system for long-term streaming video and audio interactions. *arXiv preprint arXiv:2412.09596*, 2024.
- [75] Peiyuan Zhang, Kaichen Zhang, Bo Li, Guangtao Zeng, Jingkan Yang, Yuanhan Zhang, Ziyue Wang, Haoran Tan, Chunyuan Li, and Ziwei Liu. Long context transfer from language to vision. *arXiv preprint arXiv:2406.16852*, 2024.
- [76] Yuanhan Zhang, Jinming Wu, Wei Li, Bo Li, Zejun Ma, Ziwei Liu, and Chunyuan Li. Video instruction tuning with synthetic data. *arXiv preprint arXiv:2410.02713*, 2024.
- [77] Junjie Zhou, Yan Shu, Bo Zhao, Boya Wu, Shitao Xiao, Xi Yang, Yongping Xiong, Bo Zhang, Tiejun Huang, and Zheng Liu. Mlvu: A comprehensive benchmark for multi-task long video understanding. *arXiv preprint arXiv:2406.04264*, 2024.
- [78] Luwei Zhou, Chenliang Xu, and Jason J. Corso. Towards automatic learning of procedures from web instructional videos. In *AAAI Conference on Artificial Intelligence*, 2017. URL <https://api.semanticscholar.org/CorpusID:19713015>.
- [79] Haoyi Zhu, Honghui Yang, Yating Wang, Jiange Yang, Limin Wang, and Tong He. Spa: 3d spatial-awareness enables effective embodied representation. *arXiv preprint arXiv:2410.08208*, 2024.
- [80] Zhe Zhu, Dun Liang, Songhai Zhang, Xiaolei Huang, Baoli Li, and Shimin Hu. Traffic-sign detection and classification in the wild. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2110–2118, 2016.
- [81] Orr Zohar, Xiaohan Wang, Yann Dubois, Nikhil Mehta, Tong Xiao, Philippe Hansen-Estruch, Licheng Yu, Xiaofang Wang, Felix Juefei-Xu, Ning Zhang, et al. Apollo: An exploration of video understanding in large multimodal models. *arXiv preprint arXiv:2412.10360*, 2024.
- [82] Jannik Zörn, Paul Gladkov, Sofia Dudas, Fergal Cotter, Sofi Toteva, Jamie Shotton, Vasiliki Simaiaki, and Nikhil Mohan. Wayvescenes101: A dataset and benchmark for novel view synthesis in autonomous driving. *arXiv preprint arXiv:2407.08280*, 2024.

A Details of node’s timestamp

Each event node’s timestamp is initialized as the average time of the frames it represents (e.g., if an event node spans frames from 10s to 14s, its timestamp is initialized as 12s). When two event nodes are merged, the timestamp of the new node is computed as a token-count-weighted average of the original nodes:

$$t_{\text{new}} = \frac{t_i \cdot n_i + t_j \cdot n_j}{n_i + n_j}, \quad (5)$$

where t_i, t_j are the timestamps of the original event nodes, and n_i, n_j are the numbers of visual tokens contained in each node, respectively. This weighted scheme prevents timestamp drift during multiple rounds of merging, especially when the merged nodes contain significantly different amounts of visual tokens.

B Details of OnlineIT

In this section, we provide a comprehensive description of the task categorization and data distribution of the OnlineIT dataset. It is specifically designed to enhance the streaming video understanding capabilities of MLLMs in terms of real-time perception, future prediction, and event continuity. As shown in Table 8, the dataset is divided into two major components: OnlineIT-general, which targets general streaming video understanding, and OnlineIT-drive, which focuses on autonomous driving scenarios. Each subset is carefully designed to cover a diverse range of fine-grained perception and reasoning tasks with high-quality annotations.

Table 8: Task types and data volumes of OnlineIT.

Dataset	Categories	Task	Source	Instance Num
OnlineIT-general	Spatial Perception	Spatial Grounding	RefCOCO [67] Allseeing-V2 [56]	~43k ~45k
		Multi-round Spatial Understanding	Visual Genome [27]	~43k
		Spatial Grounded VQA	Allseeing-V2 [56]	~43k
		Relative Spatial Localization	LaSOT [13]	~19k
	Temporal Perception	Temporal Grounding	Charades-STA [17] HiREST [68] QuerYD [43]	~11k ~0.4k ~13k
		Reasoning Temporal Localization	ActivityNet-RTL [20]	~10k
		Multi-format Temporal Grounding	InternVid-VTime [19]	~20k
	Spatiotemporal Perception	Spatiotemporal Action Localization	AVA [18]	~6k
		Object Backward Tracking	LaSOT [13] GOT [22]	~51k ~58k
		Spatiotemporal Detection	LaSOT [13]	~14k
	Event Perception	Dense Video Captioning	ActivityNet-Captions [26] ViTT [78] Youcook2 [21]	~10k ~5k ~1k
		Step Localization and Captioning	COIN [53] HiREST [68]	~9k ~0.5k
OnlineIT-drive	Static Target	Past Memory	D ² -City [4]	~9k
		Real-time Perception	TT100k [80] D ² -City [4]	~46k ~13k
	Dynamic Target	Localization Prediction	Road-waymo [24]	~1k
		Move Distance Prediction	Road-waymo [24]	~7k
	Event Oriented	Accident Reasoning	MM-AU [14]	~6k
		Risk Analysis	MM-AU [14]	~7k

B.1 OnlineIT-general

OnlineIT-general encompasses a broad scope of tasks designed to foster a comprehensive understanding of spatiotemporal video content in streaming settings. As shown in Table 8, the dataset is categorized into four primary task types: spatial perception, temporal perception, spatiotemporal perception, and event perception. To ensure diversity, robustness, and fine-grained task coverage, we

compiled and refined data from a wide array of sources. In total, OnlineIT-general comprises over 400k instances spanning various difficulty levels and video durations.

Spatial Perception. This task type includes four subtasks. *Spatial Grounding* requires the model to output the bounding box indicating the location of a queried object. *Multi-round Spatial Understanding* involves identifying the object’s spatial location through multi-turn dialogue or generating a caption for the object within a specified spatial region. *Spatial Grounded VQA* combines visual question answering with spatial localization, requiring the model to provide the bounding box of the relevant area while answering the question. *Relative Spatial Localization* challenges the model to determine the position of a specified object relative to the overall scene. These tasks emphasize spatial grounding and reasoning, which are crucial for enhancing a model’s fine-grained spatial perception in real-time streaming video scenarios.

Temporal Perception. This category consists of three subtasks. *Temporal Grounding* involves interpreting a natural language query and identifying the start and end timestamps of the corresponding video segment. In streaming scenarios, the model must also assess whether the described event is currently ongoing. *Reasoning Temporal Localization* requires identifying the relevant time span of an event while answering a reasoning-based question. *Multi-format Temporal Localization* incorporates both single-turn and multi-turn dialogues, covering a diverse range of question formats. These tasks focus on strengthening the MLLM’s ability to track and reason about temporal dependencies, improving its understanding of both current and past moments in a video stream.

Spatiotemporal Perception. This task type integrates spatial and temporal reasoning and includes three subtasks. *Spatiotemporal Action Localization* requires the model to predict both the spatial location and the action being performed by a target at a specific query time. *Object Backward Tracking* tasks the model with identifying the current location of an object and tracing its position at previous time points, such as one or two seconds earlier. *Spatiotemporal Detection* operates over broader temporal windows, asking whether an object visible in the current frame existed several seconds ago or requiring the model to locate an object at a specified historical moment and determine its duration of existence. These tasks combine spatiotemporal cues to capture actions, motion, and transitions, allowing the model to track object trajectories and anticipate future states based on past and present context.

Event Perception. This category includes two subtasks. *Dense Video Captioning* involves detecting a sequence of events in a video and generating corresponding timestamps along with high-level descriptions. *Step Localization and Captioning* differs by focusing on segmenting and narrating key procedural steps within long-form videos. These tasks are aimed at improving the model’s understanding of complex, multi-step events, enabling structured interpretation of dynamic sequences in streaming video understanding.

B.2 OnlineIT-drive

OnlineIT-drive is designed specifically for the domain of streaming video understanding in autonomous driving. The dataset includes 89k instances, which are organized into three major task categories. Collectively, these tasks aim to strengthen not only real-time perception capabilities but also the temporal reasoning and decision-making abilities of MLLMs in high-stakes and rapidly evolving environments.

Static Target Understanding. To improve the model’s capacity for static scene understanding, two task types are introduced. *Real-time Perception* requires the model to accurately perceive and interpret the semantics and spatial attributes of traffic-related targets as they appear in real time. *Past Memory* assesses the model’s ability to retain and retrieve the semantics and spatiotemporal characteristics of traffic targets that were observed at a prior point in time. These tasks collectively enhance the model’s capability to perceive, understand, and remember static traffic elements and environmental context, such as road infrastructure and regulatory signage.

Dynamic Target Understanding. It includes two task types that aim to enhance predictive understanding of dynamic traffic participants. *Location Prediction* requires the model to estimate

the future position of a moving target based on its historical motion trajectory. **Move Distance Prediction** focuses on predicting the distance traveled between the ego vehicle and other moving agents, given motion-related observations. These tasks are designed to improve the model’s ability to track continuously moving objects and to anticipate future trajectories.

Event Oriented Reasoning. It is intended to foster the development of reasoning abilities necessary for risk assessment and accident interpretation. **Risk Analysis** requires the model to detect potential sources of danger in the current traffic scene and to assess the likelihood of accident occurrence. **Accident Reasoning** involves post hoc analysis, where the model must infer the causes of an observed accident and articulate plausible preventive strategies. These tasks are designed to enhance the model’s ability to reason about causal relationships and to anticipate or reflect on traffic risks with contextual awareness.

C Details of ODV-Bench

In this section, we detail the task taxonomy and formulation of the ODV-Bench, as well as the dataset statistics. We categorize task scenarios based on target entities and derive key perception and reasoning task types for each scenario in Table 9.

Table 9: Overview of task categories, their subcategories, and question templates.

Task Objective Scenario	Sub-task	Query Examples
Static Target	Real-time Traffic Perception	1) What is the meaning of the traffic sign at the [0.61,0.31,0.64,0.38] in the current picture? 2) What are the position coordinates of the traffic sign indicating "Pedestrian Crossing" in the current picture? 3) What is the meaning of the road board at the [0.77,0.08,0.88,0.2] in the current picture? 4) According to the road board at the [0.09,0.46,0.19,0.52] currently, if going in the left direction, where will we go, how far is it? 5) What is the color of the traffic light at the [0.42,0.01,0.45,0.13] in the current picture? And what is its indication? 6) According to the road board at the [0.65,0.03,0.76,0.16] currently, how far is it from Fengle?
	Past Traffic Memory	1) What were the position coordinates of the traffic sign indicating "No Left Turn" in the scene 3 seconds ago? 2) What was the meaning of the traffic sign at the [0.39,0.13,0.41,0.17] in the scene 1 seconds ago? 3) The traffic sign is currently located at [0.92,0.02,0.96,0.09]. What were its coordinates 2 seconds ago? 4) What was the color of the traffic light at the [0.35,0.1,0.38,0.22] in the scene 2 seconds ago?
	Driving Decision-Making	1) According to the road board at the [0.37,0.18,0.47,0.31] in the image taken 2 seconds ago, if we want to go to Renhe, in which direction should we go and how far is it? 2) According to the road board at the [0.51,0.18,0.61,0.3] currently, if we want to go to Libai Avenue, in which direction should we go and how far is it? 3) According to the road board at the [0.38,0.04,0.63,0.23] currently, if we want to turn left, which lane should we be in?
	Key Information Extraction	1) If we want to go to Suzhou, which target should we pay the most attention to currently? Provide the type and coordinates.
	Hallucination Detection	1) According to the road board at the [0.38,0.31,0.52,0.48], how far is it currently from Qingpu Town? 2) What is the meaning of the traffic sign at the [0.34,0.29,0.38,0.38] in the current picture? 3) What is the color of the traffic light at the [0.9,0.86,0.95,0.92] in the current picture?
	Traffic Change Detection	1) At the current moment, has the traffic signal light indicating "turn right" ahead turned completely green? 2) At the current moment, has the traffic signal light ahead turned completely red?
Dynamic Target	Action Prediction	1) What will be the subsequent motion state of the car currently in the [0.993, 0.615, 1.0, 0.63] location?
	Location Prediction	1) What will the position box of the pedestrian in the [0.544, 0.561, 0.613, 0.895] location be like in the next second?
	Distance Prediction	1) Is the distance between our car and the car in the [0.488, 0.488, 0.501, 0.494] getting farther or closer? 2) Will there be significant traffic risks within a certain period in the future?
Multi-agent Interaction Event	Risk Prediction	1) Is there a high probability of traffic accidents occurring within a certain period in the future? 2) Will there be significant traffic risks within a certain period in the future?
	Risk Analysis	1) There is a high risk of traffic accidents at present. Based on the environment, what types of accidents are likely to occur, and what is the basis for this prediction? 2) There are significant traffic risks at present. Based on the environment, what are the sources of these risks and what types of accidents might they cause?
	Accident Reason Answering	1) What is the cause of the accident in the video? What measures can be taken to avoid it?

C.1 Task Taxonomy and Formulation

We first identify the primary categories of traffic entities relevant to autonomous driving and organize task scenarios into three groups: **(1) Tasks for Static Targets**, which involve the recognition and retrieval of stationary traffic elements such as traffic signs, lights, and road indicators; **(2) Tasks for dynamic targets**, which focus on behavior prediction and localization of moving entities such as vehicles and pedestrians; and **(3) Tasks for multitarget interaction events**, which capture complex interactions, risk scenarios, and accidents involving multiple agents. Based on these categories and guided by temporal cues and the practical needs of driving, we further define fine-grained task types to comprehensively assess model understanding in realistic online driving video scenarios.

Static target oriented tasks			
[RTP]	Real-time Traffic Perception	Q: What are the position coordinates of the traffic sign indicating "Pedestrian Crossing" currently? (A) [0.45,0.37,0.59,0.53] (B) [0.47,0.72,0.78,0.87] (C) [0.54,0.54,0.73,0.83] (D) [0.87,0.0,0.94,0.11] Answer: (D)	
[PTM]	Past Traffic Memory	Q: What was the meaning of the traffic sign at the [0.0,0.39,0.05,0.5] in the scene 2 seconds ago? (A) Zone Speed Limit 30 (B) No U-Turn (C) No Left Turn (D) Height Restriction 3 Answer: (B)	
[DDM]	Driving Decision-Making	Q: According to the traffic sign at the [0.77,0.03,0.84,0.11] currently, if we want to go to Zhuhai, in which direction should we go? (A) Left (B) Front left (C) Straight (D) Right Answer: (D)	
[KIE]	Key Information Extraction	Q: If we want to go to Wenjiang, which target should we pay the most attention to currently? (A) Car, [0.28,0.13,0.52,0.97] (B) Road board, [0.6,0.0,0.74,0.27] (C) Road board, [0.78,0.1,0.86,0.24] Answer: (B)	
[HD]	Hallucination Detection	Q: What is the color of the traffic light at the [0.5,0.64,0.54,0.69] in the current picture? (A) Yellow (B) Green (C) Unable to say (D) Red Answer: (C)	
[TCD]	Traffic Change Detection	Q: At the current moment, has the traffic light indicating "turn right" ahead turned green? Query Time: 0.00 Answer: No (17.43s) → No (18.43s) → Yes (19.43s) → Yes (20.43s)	
Dynamic target oriented tasks			
[AP]	Action Prediction	Q: What will be the subsequent motion state of the bus currently in the [0.35, 0.36, 0.57, 0.68] location? (A) Crossing road (B) Turning right (C) Moving to the right lane (D) Moving to the left lane Answer: (D)	
[LP]	Location Prediction	Q: What will the position box of the cyclist in the [0.25, 0.53, 0.36, 0.74] location be like in the next second? (A) [0.20, 0.31, 0.53, 0.49] (B) [0.67, 0.52, 0.80, 0.73] (C) [0.88, 0.96, 1.00, 0.69] (D) [0.90, 0.04, 0.41, 0.61] Answer: (B)	
[DP]	Distance Prediction	Q: Is the distance between our car and the car in the [0.37, 0.60, 0.61, 0.88] getting farther or closer? (A) Getting closer (B) Getting farther Answer: (B)	
Event oriented tasks for multi-agent interaction			
[RP]	Risk Prediction	Q: Will there be significant traffic risks within a certain period in the future? Query Time: 0.00 Answer: No (2.80s) → No (20.00s) → Yes (27.50s)	
[RA]	Risk Analysis	Q: There are significant traffic risks at present. Based on the environment, what are the sources of these risks and what types of accidents might they cause? Answer: A vehicle crosses the road when we go straight, and our vision is blocked. This may lead that we hit a crossing car.	
[ARA]	Accident Reason Answering	Q: What is the cause of the accident in the video? What measures can be taken to avoid it? Answer: We run red light. We should strictly abide by the traffic rules during driving. When the red light is on, we should brake in time.	

Figure 6: Examples of each task in ODV-Bench. The 12 tasks are divided into three different perception modes for online video understanding for autonomous driving.

C.1.1 Tasks for Static Targets

Static traffic elements, such as traffic signs and road indicators, play a crucial role in driving decisions and hazard avoidance under normal driving conditions. To evaluate the model’s ability to retrieve and recognize these elements in online video streams, we design a dedicated set of tasks. Specifically, we distinguish between basic perception tasks and more advanced reasoning tasks, and further refine them based on temporal cues and practical driving needs: (1) **Real-time Traffic Perception**: Perceive

and interpret the semantics and spatial locations of static traffic elements in real time; **(2) Past Traffic Memory:** Recall and track the semantics and spatiotemporal states of previously observed static elements; **(3) Driving Decision-Making:** make driving decisions based on the perceived information; **(4) Key Information Extraction:** Identify and locate key traffic elements critical to driving decisions; **(5) Hallucination Detection:** identify questions irrelevant to the existing video input; and **(6) Traffic Change Detection:** detect timestamps for changes in traffic elements, such as traffic lights.

C.1.2 Tasks for Dynamic Targets

The position and behavior of other road participants, such as vehicles and pedestrians, are crucial reference factors influencing autonomous driving decisions and safety. The ability to predict the position and behavior of dynamic traffic objects is essential to ensure the safety of autonomous driving. Therefore, we focus on the following three tasks to effectively evaluate this capability: **(1) Action Prediction:** predicting the next action of vehicles and pedestrians based on continuous spatiotemporal cues; **(2) Distance Prediction:** predicting the relative distance change between the ego-vehicle and other vehicles based on motion information; and **(3) Location Prediction:** predicting the future spatial position of dynamic traffic targets based on their movement trajectories.

C.1.3 Tasks for Multi-Target Interaction Events

To achieve safe and reliable autonomous driving, the system must be able to identify risks and analyze accidents in complex road interaction scenarios. In the context of online video streams, this ability involves the dynamic recognition and analysis of multi-agent interactions, as well as the reasonable prediction of traffic risks. To evaluate this capability, we design the following three task categories: **(1) Risk Prediction:** predicting the occurrence of significant traffic risks and responding proactively; **(2) Risk Analysis:** detecting the sources of current traffic risks and analyzing the potential causes of accidents; and **(3) Accident Reason Answering:** post-accident analysis, providing potential causes for the incident and summarizing actionable lessons learned.

C.2 Dataset Statistics

ODV-Bench comprises 1,190 unique first-person driving video clips, encompassing a diverse range of driving scenarios across different countries from routine driving conditions to potential hazards and accidents. The length of videos ranges from 5 seconds to 90 seconds, effectively capturing the diversity of real-world streaming driving experiences. The benchmark includes 6,322 question-answer pairs, with an average query timestamp of 18.9 seconds. Specifically, the static-object-oriented category comprises 247 videos with a total of 1,639 questions; the dynamic-object-oriented category includes 162 videos and 2,973 questions; and the event-oriented category consists of 781 videos with 1,710 questions. All questions are in multiple-choice format, with the number of options varying between 2 and 4 depending on the question type.

D More Implementation Details

Table 10: Parameter settings for three-stage offline pre-training.

		Stage-1	Stage-2	Stage-3
Vision	Resolution×Num. frames	384	384×8	Max 384×512
	#Tokens	64×4	64×8	Max 16×512
Data	Dataset	Image & Short Video	Image & Short Video	Image & Short / Long Video
	#Samples	0.6M & 0.5M	3.8M & 3.4M	0.5M & 2.8M
Model	Trainable	Projector	Full Model	Full Model
	#parameters	16.98MB	8030.35MB	8030.35MB
Training	Batch Size	512	256	256
	LR of vision encoder	1×10^{-3}	2×10^{-6}	2×10^{-6}
	LR of connector & LLM	1×10^{-3}	1×10^{-5}	1×10^{-5}
	Epoch	1	1	1

Table 11: Parameter settings for the fourth stage online fine-tuning and fifth dirve fine-tuning.

		Stage 4	Stage5
<i>Data</i>	Dataset	Image & (Short/Long/Online)-Video	Image & (Short/Long/Online)-Video
	#Samples	0.4M & 1.3M	0.2M & 0.5M
<i>Model</i>	Trainable	Projector & LLM	Projector & LLM
	#parameters	7632.60MB	7632.60MB
<i>Vision</i>	Resolution	384×384	384×384
	Frames	2~512	2~512
	FPS	1	1
<i>Memory</i>	Real-time Perception Qouta	729	729
	Spatiotemporal Memory Quota	128 × 18	128 × 18
	Total Visual Token Limits	8192	8192
	Similarity Penalty Weight	0.4	0.4
	Merge Count Penalty Weight	0.4	0.4
	Temporal Distance Penalty Weight	0.2	0.2
<i>Training</i>	Batch Size	256	256
	LR	1×10^{-5}	1×10^{-5}
	Epoch	1	1
	Optimizer	AdamW	AdamW
	Weight Decay	0	0
	Warmup Ratio	0.03	0.03
	LR Schedule	cosine	cosine
	Vision Select Layer	-2	-2
	GPU Num s	32	32

We adopt a five-stage training strategy to systematically train the proposed StreamForest model, aiming to fully exploit its potential for streaming video understanding tasks. In the first three stages, we follow and extend the training paradigm of VideoChat-Flash [33], employing offline training to endow the model with strong capabilities in long-form video comprehension and cross-modal alignment. These stages are designed progressively, covering diverse data scales and task objectives, enabling the model to gradually acquire core competencies such as basic vision-language alignment, long-term temporal modeling, and complex scene reasoning. Detailed training procedures and hyperparameter configurations for these stages are provided in Table 10.

In the fourth and fifth stages, we perform online fine-tuning to enhance the model’s ability to process streaming inputs in realistic scenarios. By continuously feeding frame sequences during training, the model learns to retain a fine-grained perception of the current moment while maintaining long-term memory of past events, even under high compression constraints. The full configuration and parameter settings for the online fine-tuning phase are listed in Table 11. These stages are critical for transitioning the model from offline understanding to real-time reasoning, significantly improving its robustness and practical effectiveness in real-world applications.

E Full Performances

In the following parts, we present the full results and compare StreamForest with leading proprietary and open-source models. To comprehensively evaluate the effectiveness of StreamForest, we conduct experiments on three online video understanding benchmarks: StreamingBench, OVBench, and OVO-Bench.

E.1 StreamingBench

Table 12 presents the full evaluation results on StreamingBench, covering 12 real-time video understanding tasks. StreamForest achieves the highest average score (77.26%) among all evaluated models, both open-source and proprietary, while operating efficiently at 1 fps. Notably, StreamForest outperforms leading proprietary MLLMs such as GPT-4o (73.28%) and Gemini 1.5 Pro (75.69%). It also significantly surpasses top open-source offline models such as LLaVA-OneVision (71.12%) and Qwen2.5-VL (73.68%), underscoring its robust multimodal representation and reasoning capabilities. In the online video MLLM category, StreamForest sets a new state-of-the-art, outperforming

Table 12: Full evaluation results of real-time understanding tasks on StreamingBench.

Method	Size	#Frames	OP	CR	CS	ATP	EU	TR	PR	SU	ACP	CT	ALL
Human	-	-	89.47	92.00	93.60	91.47	95.65	92.52	88.00	88.75	89.74	91.30	91.46
<i>Proprietary MLLMs</i>													
Gemini 1.5 pro [54]	-	1fps	79.02	80.47	83.54	79.67	80.00	84.74	77.78	64.23	71.95	48.70	75.69
GPT-4o [44]	-	64	77.11	80.47	83.91	76.47	70.19	83.80	66.67	62.19	69.12	49.22	73.28
Claude 3.5 Sonnet [1]	-	20	73.33	80.47	84.09	82.02	75.39	79.53	61.11	61.79	69.32	43.09	72.44
<i>Open-source Offline Video MLLMs</i>													
Video-LLaMA2 [10]	7B	32	55.86	55.47	57.41	58.17	52.80	43.61	39.81	42.68	45.61	35.23	49.52
VILA-1.5 [38]	8B	14	53.68	49.22	70.98	56.86	53.42	53.89	54.63	48.78	50.14	17.62	52.32
Video-CCAM [15]	14B	96	56.40	57.81	65.30	62.75	64.60	51.40	42.59	47.97	49.58	31.61	53.96
LongVA [75]	7B	128	70.03	63.28	61.20	70.92	62.73	59.50	61.11	53.66	54.67	34.72	59.96
InternVL2 [9]	8B	16	68.12	60.94	69.40	77.12	67.70	62.93	59.26	53.25	54.96	56.48	63.72
Kangaroo [40]	7B	64	71.12	84.38	70.66	73.20	67.08	61.68	56.48	55.69	62.04	38.86	64.60
LLaVA-NeXT-Video [76]	32B	64	78.20	70.31	73.82	76.80	63.35	69.78	57.41	56.10	64.31	38.86	66.96
MiniCPM-V2.6 [65]	8B	32	71.93	71.09	77.92	75.82	64.60	65.73	70.37	56.10	62.32	53.37	67.44
LLaVA-OneVision [28]	7B	32	80.38	74.22	76.03	80.72	72.67	71.65	67.59	65.45	65.72	45.08	71.12
Qwen2.5-VL [2]	7B	1fps	78.32	80.47	78.86	80.45	76.73	78.50	79.63	63.41	66.19	53.19	73.68
<i>Open-source Online Video MLLMs</i>													
Flash-VStream [72]	7B	-	25.89	43.57	24.91	23.87	27.33	13.08	18.52	25.20	23.87	48.70	23.23
VideoLLM-online [5]	8B	2fps	39.07	40.06	34.49	31.05	45.96	32.40	31.48	34.16	42.49	27.89	35.99
Dispidier [47]	7B	1fps	74.92	75.53	74.10	73.08	74.44	59.92	76.14	62.91	62.16	45.80	67.63
StreamForest(Ours)	7B	1fps	83.11	82.81	82.65	84.26	77.50	78.19	76.85	69.11	75.64	54.40	77.26

open-source counterparts Dispidier (67.63%) by a wide margin. Its consistent accuracy and real-time efficiency demonstrate a strong potential for practical deployment in streaming applications.

E.2 OVBench

Table 13: Full evaluation results on OVBench.

Task Name	Size	FP			THV			PM			SP		STP		TP			AVG
Subset Name		AA	GSP	MP	AP	SV	OP	AR	PR	TR	AL	OP	AT	OT	AS	SL	OES	
Proprietary MLLMs																		
Gemini-1.5-Flash [54]	-	71.4	53.6	21.9	56.5	60.8	40.6	36.7	47.9	62.5	32.3	37.5	87.0	50.0	83.3	22.3	46.9	50.7
Open-source Offline Video MLLMs																		
InternVL2 [9]	7B	52.6	60.2	27.6	57.5	52.0	58.5	38.8	67.1	58.3	38.1	31.3	87.4	37.0	75.4	31.4	5.9	48.7
InternVL2 [9]	4B	57.7	57.0	14.4	59.2	49.4	60.0	30.3	61.8	46.3	30.9	20.1	83.0	32.3	70.7	29.4	3.4	44.1
LLaMA-VID [35]	7B	43.6	50.9	19.6	64.0	47.5	46.8	29.4	48.9	51.2	31.9	11.2	75.7	24.8	59.1	26.0	40.0	41.9
LLaVA-Onevision [28]	7B	68.0	62.7	35.9	58.4	50.3	46.5	29.4	60.7	58.0	43.1	14.2	86.5	49.7	70.7	28.1	30.2	49.5
LongVA [75]	7B	64.1	56.5	29.5	54.9	51.9	34.8	35.3	55.6	57.7	31.6	3.4	67.4	44.7	80.0	26.7	4.0	43.6
MiniCPM-V2.6 [65]	7B	33.3	35.9	15.0	59.2	50.8	55.1	25.0	37.4	41.7	26.6	11.8	98.3	36.3	66.1	26.4	6.2	39.1
Qwen2-VL [55]	7B	60.3	66.1	22.1	54.9	51.5	37.8	64.4	69.3	35.3	28.5	97.0	49.4	65.1	30.8	11.7	49.7	49.7
LITA [20]	7B	19.2	24.5	19.9	40.8	48.9	24.9	3.1	27.3	6.4	6.9	14.6	35.2	23.9	27.4	0.5	3.4	20.4
TimeChat [48]	7B	7.7	15.3	18.7	20.6	15.7	11.7	9.1	14.7	9.8	7.5	19.5	13.9	10.3	9.3	10.1	10.8	12.8
VTimeLLM [19]	7B	37.2	23.4	15.0	64.8	43.8	53.2	25.9	38.8	32.5	25.9	20.4	40.9	6.8	48.4	43.5	8.6	33.1
Open-source Online Video MLLMs																		
VideoLLM-Online [5]	7B	0	1.8	20.9	5.2	5.9	32.6	0	2.3	26.7	0.6	26.6	0.9	19.9	0.9	1.7	8.3	9.6
MovieChat [52]	7B	23.1	27.5	23.6	58.4	43.9	40.3	25.6	31.1	23.9	26.9	39.6	24.4	28.9	29.3	25.5	21.9	30.9
Flash-Vstream [72]	7B	26.9	37.6	23.9	60.1	41.9	40.0	23.4	35.3	26.1	24.7	28.8	27.0	21.4	29.8	25.6	26.8	31.2
Videochat-Online [23]	4B	64.1	59.7	16.6	63.1	58.3	62.8	42.2	54.4	70.6	54.1	24.8	88.7	48.5	73.0	25.9	71.7	54.9
StreamForest (Ours)	7B	69.2	60.0	34.4	69.1	54.0	72.9	50.9	64.9	82.2	56.6	87.9	95.2	61.2	64.2	30.6	92.6	60.5

Table 13 shows the comprehensive results on OVBench, encompassing six diverse task categories (FP, THV, PM, SP, STP, TP). StreamForest achieves the top average score of 60.5%, surpassing all open-source online and offline Video MLLMs. It significantly outperforms other open-source online models, e.g., Videochat-Online (54.9%) and Flash-VStream (31.2%), as well as offline models such as Qwen2-VL (49.7%) and LLaVA-OneVision (49.5%). Compared to Gemini-1.5-Flash (50.7%), StreamForest delivers nearly 10 points higher accuracy on average, affirming its capability to balance real-time efficiency with high performance.

E.3 OVO-Bench

Table 14 details performance on OVO-Bench, where StreamForest again leads among open-source online video MLLMs with an overall average of 55.57%, outperforming Dispidier-7B (41.78%) and Flash-VStream-7B (33.15%). It excels in critical areas such as real-time visual perception (61.20%), backward tracing (52.02%), and forward active responding (53.49%), showcasing robust temporal

Table 14: Detailed evaluation results on OVO-Bench.

Model	# Frames	Real-Time Visual Perception							Backward Tracing				Forward Active Responding				Overall Avg.
		OCR	ACR	ATR	STU	FPD	OJR	Avg.	EPM	ASI	HLD	Avg.	REC	SSR	CRR	Avg.	
Human	-	93.96	92.57	94.83	92.70	91.09	94.02	93.20	92.59	93.02	91.37	92.33	95.48	89.67	93.56	92.90	92.81
<i>Proprietary MLLMs</i>																	
Gemini 1.5 Pro [54]	1fps	85.91	66.97	79.31	58.43	63.37	61.96	69.32	58.59	76.35	52.64	62.54	35.53	74.24	61.67	57.15	63.00
GPT-4o [44]	64	69.80	64.22	71.55	51.12	70.30	59.78	64.46	57.91	75.68	48.66	60.75	27.58	73.21	59.40	53.40	59.54
<i>Open-source Offline Video MLLMs</i>																	
LLaVA-Video-7B [76]	64	69.80	59.63	66.38	50.56	72.28	61.41	63.34	51.18	64.19	9.68	41.68	34.10	67.57	60.83	54.17	53.06
LLaVA-OneVision-7B [28]	64	67.11	58.72	69.83	49.44	71.29	60.33	62.79	52.53	58.78	23.66	44.99	24.79	66.93	60.83	50.85	52.88
Qwen2-VL-7B [55]	64	69.13	53.21	63.79	50.56	66.34	60.87	60.65	44.44	66.89	34.41	48.58	30.09	65.66	50.83	48.86	52.70
InternVL2-8B [9]	64	68.46	58.72	68.97	44.94	67.33	55.98	60.73	43.10	61.49	27.41	44.00	25.79	57.55	52.92	45.42	50.05
LongVU-7B [50]	1fps	55.70	49.54	59.48	48.31	68.32	63.04	57.40	43.10	66.22	9.14	39.49	16.62	69.00	60.00	48.54	48.48
<i>Open-source Online Video MLLMs</i>																	
VideoLLM-online-8B [5]	2fps	8.05	23.85	12.07	14.04	45.54	21.20	20.79	22.22	18.80	12.18	17.73	-	-	-	-	12.84
Flash-VStream-7B [72]	1fps	25.50	32.11	29.31	33.71	29.70	28.80	29.86	36.36	33.78	5.91	25.35	5.44	67.25	60.00	44.23	33.15
Dispider-7B [47]	1fps	57.72	49.54	62.07	44.94	61.39	51.63	54.55	48.48	55.41	4.30	36.06	18.05	37.36	48.75	34.72	41.78
StreamForest-7B (Ours)	1fps	68.46	53.21	71.55	47.75	65.35	60.87	61.20	58.92	64.86	32.26	52.02	32.81	70.59	57.08	53.49	55.57

reasoning across both past and future events. These results position StreamForest as a practical and powerful solution for real-time video-language understanding.

F Qualitative Comparison

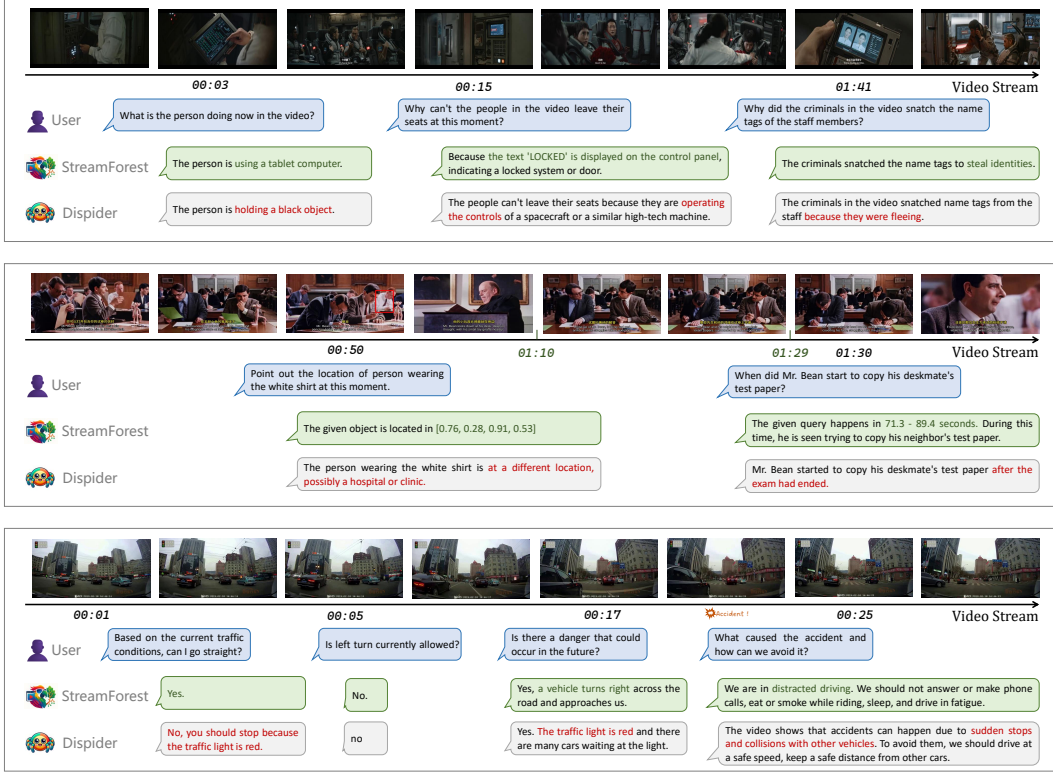


Figure 7: Qualitative comparison between StreamForest and other method.

Figure 7 presents a qualitative comparison between our model and other method. In the top example, StreamForest demonstrates a superior ability to capture fine-grained visual details and maintain persistent memory over time, enabling more coherent and informed inferences. The middle example highlights StreamForest's strong spatiotemporal grounding capabilities, accurately localizing objects and events across space and time. The bottom example illustrates the model's potential in intelligent driving scenarios, where it delivers precise real-time perception and supports future predictions based on both historical and current observations.

G More Ablations




Figure 8: Ablation experiments of three penalty weights.

To evaluate the effect of each penalty on the effectiveness of long-term memory, we conducted ablation studies by varying the weights of the similarity penalty, merge count penalty, and temporal distance penalty. The results are presented in Figure 8, which reports the accuracy of both VideoMME and OVBenCh under different settings. It demonstrates that a balanced combination of penalty weights is more effective. Specifically, 0.4 for both similarity and merge count penalties, and 0.2 for the temporal distance penalty yield the most effective memory construction. This configuration achieves a favorable trade-off between preserving semantic coherence, maintaining diversity in memory representation, and ensuring reasonable temporal continuity.

H Efficiency of Multi-round Inference

We evaluated StreamForest’s multi-round response efficiency by streaming a 600-second video to the model at a constant rate of 1 FPS. To isolate processing throughput from text generation latency, the model was constrained to produce a single-token response for each frame. Under this rigorous setting, StreamForest achieved an average processing speed of 9.9 FPS, which is competitive with VideoLLM-Online (12.3 FPS), a model renowned for its real-time capabilities. Crucially, StreamForest delivers this high efficiency without compromising its substantial superiority in reasoning accuracy over VideoLLM-Online. In stark contrast, Qwen2-VL, another model that also prioritizes reasoning accuracy, demonstrated severe performance bottlenecks. Its processing speed dropped below 1 FPS on a video merely two minutes long, and it encountered out-of-memory (OOM) errors on a single A100-80G GPU after processing only 79 frames.

Table 15: Comparison of multi-round inference speed.

Method	Resolution	FPS
Qwen2.5-VL	384	OOM
VideoLLM-Online	384	12.3
StreamForest (1k)	384	9.9

I Discussions

I.1 Limitations

Despite the effectiveness of our proposed method, several limitations remain that warrant further investigation. Our approach can only rely on computing inter-frame similarity to determine moments when the model should proactively produce outputs. Specifically, the method identifies local minima in similarity scores to detect transitions. However, this technique primarily captures coarse scene changes and often fails to accurately detect true semantic event boundaries. To address this limitation, one possible solution is to incorporate a lightweight MLLM as an auxiliary reminder module. This module could provide semantic-level guidance to support more precise and context-aware output decisions. These limitations suggest promising directions for future work.

I.2 Broader Impacts

Our proposed method shows strong potential for real-world streaming video understanding, especially in critical applications like autonomous driving. With domain-specific fine-tuning, it can be adapted to various downstream tasks that require continuous visual processing. As shown in the main text, the model performs well in autonomous driving scenarios, where accurate and timely perception is crucial for safety and decision-making. It can efficiently process live video streams while preserving fine-grained perception and long-term contextual memory. This capability is particularly valuable under limited computational resources, helping improve the reliability and responsiveness of intelligent systems in dynamic environments.

However, as with many vision-language models, potential negative social impacts must also be considered. If deployed without proper safeguards, models may inherit or amplify biases present in training data, leading to unreliable behavior. For instance, performance disparities across different environments or conditions (e.g., weather, lighting, or geographic location) could affect the robustness of StreamForest. To mitigate such risks, we should explore techniques for enhancing interpretability and controllability of streaming video models in safety contexts.